

Vitor de Almeida Silva

Prof. Orientador: Prof. Dr. Marcos Paulino Roriz Junior

Profa. Coorientadora: Profa. Dra. Michelle Carvalho Galvão da Silva Pinto
Bandeira

**DETECÇÃO DE DIMENSÕES DE BAGAGENS
AEROPORTUÁRIAS A PARTIR DE
DISPOSITIVOS DE BAIXO CUSTO**

Aparecida de Goiânia - GO

Dezembro, 2023

Vitor de Almeida Silva

Prof. Orientador: Prof. Dr. Marcos Paulino Roriz Junior

Profa. Coorientadora: Profa. Dra. Michelle Carvalho Galvão da Silva Pinto
Bandeira

**DETECÇÃO DE DIMENSÕES DE BAGAGENS
AEROPORTUÁRIAS A PARTIR DE DISPOSITIVOS DE
BAIXO CUSTO**

Texto de dissertação submetido para defesa
no Programa de Pós-Graduação em Engenharia
de Produção.

Universidade Federal de Goiás – UFG

Faculdade de Ciências e Tecnologia

Programa de Pós-Graduação em Engenharia de Produção

Aparecida de Goiânia - GO

Dezembro, 2023

Vitor de Almeida Silva

Prof. Orientador: Prof. Dr. Marcos Paulino Roriz Junior

Profa. Coorientadora: Profa. Dra. Michelle Carvalho Galvão da Silva Pinto Bandeira
DETECÇÃO DE DIMENSÕES DE BAGAGENS AEROPORTUÁRIAS

A PARTIR DE DISPOSITIVOS DE BAIXO CUSTO/ Vitor de Almeida Silva

Prof. Orientador: Prof. Dr. Marcos Paulino Roriz Junior

Profa. Coorientadora: Profa. Dra. Michelle Carvalho Galvão da Silva Pinto
Bandeira. – Aparecida de Goiânia - GO, Dezembro, 2023- 74 p. : il.(alguma
color.); 30 cm.

Texto de dissertação (Mestrado) – Universidade Federal de Goiás – UFG

Faculdade de Ciências e Tecnologia

Programa de Pós-Graduação em Engenharia de Produção, Dezembro, 2023.

1. Reconstrução 3D. 2. *Self Bag Drop*. 3. Dimensões de Bagagens. 4. visão
computacional. I. Prof. Dr. Marcos Paulino Roriz Junior. II. Profa. Dra. Michelle
Carvalho Galvão da Silva Pinto Bandeira III. Universidade Federal de Goiás.
IV. Programa de Pós-graduação em Engenharia de Produção V. Detecção de
dimensões de bagagens aeroportuárias a partir de dispositivos de baixo custo

CDU xx:xxx:xxx.x

Vitor de Almeida Silva

Prof. Orientador: Prof. Dr. Marcos Paulino Roriz Junior
Profa. Coorientadora: Profa. Dra. Michelle Carvalho Galvão da Silva Pinto
Bandeira

DETECÇÃO DE DIMENSÕES DE BAGAGENS AEROPORTUÁRIAS A PARTIR DE DISPOSITIVOS DE BAIXO CUSTO

Texto de dissertação submetido para defesa
no Programa de Pós-Graduação em Engenharia
de Produção.

Trabalho aprovado. Aparecida de Goiânia - GO, 20 de dezembro de 2023

Prof. Dr. Marcos Paulino Roriz Junior
Orientador – Universidade Federal de Goiás

**Profa. Dra. Michelle Carvalho Galvão
da Silva Pinto Bandeira**
Coorientadora – Universidade Federal de
Goiás

Prof. Dr. Diogo de Souza Rabelo
Membro Interno – Universidade Federal de
Goiás

Prof. Dr. Marcelo Xavier Guterres
Membro Externo – Instituto Tecnológico de
Aeronáutica

Aparecida de Goiânia - GO
Dezembro, 2023

*“Não importa o quanto tente,
você sozinho não pode mudar o mundo.
Mas este é o lado bonito do mundo.“
(L - Death Note)*

Resumo

Estudos recentes mostram um aumento significativo no tempo de embarque de passageiros, variando de 22 minutos para 40 minutos no período de 1990 a 2009. Uma das causas desse atraso é o processo de check-in, em maior parte devido à verificação das dimensões de bagagens de mão e de porão. As dimensões influenciam no armazenamento das bagagens e no gasto com a carga, caso não estejam nos padrões o cliente poderá pagar taxas extras e ser orientado a voltar à fila de *check-in*. Para amenizar o problema, empresas estão investindo em *self bag drop*. Nessa lógica, o passageiro fica responsável pelas medidas. Entretanto, pode-se gerar erros devido ao formato da bagagem e a complexidade de lidar com objetos despachados em conjunto. O presente trabalho constatou que alguns dispositivos conseguem obter automaticamente as dimensões de objetos/bagagens, em especial equipamentos baseados na tecnologia a LASER. Contudo, são equipamentos com preços expressivos e que comumente requerem uma instrumentação e modificação do ambiente para sua instalação. Com isso, esta pesquisa busca investigar a viabilidade técnica de se utilizar dispositivos de baixo custo na obtenção das dimensões de bagagens aeroportuárias. Dentre as técnicas de baixo custo, destaca-se o uso do sensor de profundidade Microsoft Kinect, capaz de obter uma nuvem de pontos (*point cloud*) do objeto em análise. Com base neste sensor, desenvolveu-se um algoritmo para capturar, montar e analisar a *point cloud* gerada, obtendo assim a dimensão da bagagem. Para validar a abordagem, foi construído um protótipo que contém uma esteira e uma estrutura para fixar o sensor, permitindo a configuração de velocidade e parâmetros de captura dos dados, como passo de amostragem e região de captura. Os testes realizados indicam ser possível obter dados de profundidade, largura e altura com precisão pelo uso do sensor de profundidade Microsoft Kinect V2. Tais resultados demonstram o potencial de uso dessa alternativa de baixo custo no gerenciamento das operações de embarque e investimentos das companhias aéreas.

Palavras-chaves: Reconstrução 3D. *self bag drop*. dimensões de bagagens. visão computacional.

Detection of airport baggage dimensions from low-cost devices - Abstract

Recent studies indicate a significant increase in passenger boarding times, ranging from 22 to 40 minutes between 1990 and 2009. One contributing factor to this delay is the check-in process, primarily stemming from baggage dimension verification. Incorrect dimensions not only impact luggage storage but also result in additional costs for the customer. In such cases, passengers may be required to pay extra fees and return to the check-in line for corrections. To address this issue, companies are investing in self-bag drop systems, where passengers take responsibility for measuring their baggage. However, challenges arise due to the varied shapes of luggage and the complexities of handling multiple checked items. This study reveals that certain devices, particularly those utilizing LASER technology, can automatically obtain baggage dimensions. Despite their effectiveness, these devices often come with a significant price, and may require adjustments to the environment for installation. Consequently, this research aims to explore the technical feasibility of employing low-cost devices to measure airport luggage dimensions. Among the low-cost techniques, the use of the Microsoft Kinect depth sensor stands out, capable of obtaining a point cloud of the object under analysis. Based on this sensor, an algorithm was developed to capture, assemble and analyse the point cloud generated, thus obtaining the size of the luggage. To validate the approach, a prototype was built that contains a mat and a structure to fix the sensor, allowing the configuration of speed and data capture parameters, such as sampling step and capture region. The conducted tests indicate that the Microsoft Kinect V2 depth sensor can accurately capture depth, width, and height data. These results indicate the potential of this low-cost alternative in streamlining airline boarding operations.

Keywords: 3D Reconstruction. *self bag drop*. luggage dimensions. computer vision.

Listas de ilustrações

Figura 1 – Fluxograma da revisão sistemática conforme o protocolo PRISMA	18
Figura 2 – Dispositivos para captura de <i>point clouds</i>	21
Figura 3 – Processo de obtenção de <i>point clouds</i> com scanner a laser	22
Figura 4 – <i>self bag drop</i> de 10Hz e 40cm/s com Scanner URL-04LX (GAO et al., 2018)	23
Figura 5 – Sensor LIDAR escaneando ambiente externo. Adaptado de (MATHWORKS, 2022b)	23
Figura 6 – Captura de um ponto com visão binocular. Adaptado de (HU et al., 2020)	24
Figura 7 – Kinect V2	25
Figura 8 – Processo de obtenção da <i>point cloud</i> usando um sensor de profundidade	26
Figura 9 – Gráficos de comparação relativa entre as soluções levantadas e outras do mercado	28
Figura 10 – Aplicação convex hull em 2D e 3D	29
Figura 11 – AABB e OMBB 2D e 3D, convex hull em azul-claro. Adaptado de (DAVID, 2014)	30
Figura 12 – Fluxograma OMBB. Adaptado de (DAVID, 2014)	31
Figura 13 – Classificação dos pontos e definição dos clusters em uma <i>point cloud</i> (DBSCAN) (HARMAN, 2020)	33
Figura 14 – Possíveis erros ao lidar com mais de uma bagagem	37
Figura 15 – Fluxograma do modelo proposto para obtenção de dimensões	40
Figura 16 – Amostragem de <i>point cloud</i> via sensor kinect	42
Figura 17 – Posições mais comuns para o sensor	42
Figura 18 – Estrutura de testes com kinect para amostragem estática	43
Figura 19 – Cenário de teste com reconstrução visual, <i>point cloud</i> com região de interesse (roi) = 40 cm x 40 cm x 50 cm	43
Figura 20 – Modelo do protótipo físico para obtenção de dimensões de bagagens	44
Figura 21 – Simulação do Circuito da Central de controle da esteira	46
Figura 22 – Central de controle da esteira	47
Figura 23 – Painel de controle do protótipo	47
Figura 24 – Protótipo do sistema com esteira e estrutura para posicionar o sensor	48
Figura 25 – <i>Point cloud</i> do ambiente da esteira	48
Figura 26 – <i>Point cloud</i> da mala 1 e tamanho do slice por captura. (b) slice1 = 5 cm x 50 cm x 50 cm. (c) slice2 = 1 cm x 50 cm x 50 cm	49
Figura 27 – Fluxo de tratamento da <i>point cloud</i> de bagagens para extração de dimensões slice = 5 cm x 50 cm x 50 cm	50
Figura 28 – Filtragem de <i>point cloud</i> de uma mala N = 3, threshold = 1	52

Figura 29 – Testes Com malas deitadas (convex hull e OMBB)	55
Figura 30 – Testes com malas em pé (point cloud, convex hull e OMBB)	56
Figura 31 – Testes com malas de lado (<i>point cloud</i> , convex hull e OMBB)	57
Figura 32 – Modelo técnico A320. Adaptado de (CARGO, 2023)	59
Figura 33 – Benchmark processo de check-in. Adaptado de (IATA, 2022)	61
Figura 34 – Interface de usuário do protótipo desenvolvido na presente pesquisa . .	73

Lista de tabelas

Tabela 1 – Avaliação relativa entre as soluções levantadas nessa pesquisa e demais soluções tecnológicas (adaptado de (RONZANI et al., 2019))	27
Tabela 2 – Comparação entre as tecnologias dos trabalhos selecionados na revisão sistemática	33
Tabela 3 – exatidão do protótipo para alturas diferentes do sensor	54
Tabela 4 – Resultado da exatidão do protótipo, malas deitadas	56
Tabela 5 – Resultado da exatidão do protótipo, malas de pé	57
Tabela 6 – Resultado da exatidão do protótipo, malas de lado	57
Tabela 7 – Comparação dos MAEs em diferentes posições	58
Tabela 8 – Definições técnicas da aeronave A320 (CARGO, 2023)	60
Tabela 9 – Dimensionamento da operação do modelo proposto em comparação com diferentes métricas de mercado para aeronave A320	61

Lista de abreviaturas e siglas

2D ou R^2	2 dimensões
3D ou R^3	3 dimensões
ANAC	Agência Nacional de Aviação Civil
AABB	Axes Align Bounding Box
DBSCAN	Density-Based Spatial Clustering of Applications with Noise
KPI	Key Performance Indicators
LASER	Light Amplification by the Stimulated Emission of Radiation
LiDAR	Light Detection and Ranging
MAE	Mean Absolute Error
MBB	Minimum Bounding Box
OMBB	Oriented Minimum Bounding Box
PDI	Processamento Digital de Imagens
RGB	Red, Green, and Blue

Sumário

1	Introdução	13
1.1	Justificativa	14
1.2	Objetivos	15
1.3	Organização do Trabalho	15
2	Referencial teórico	17
2.1	Fundamentação teórica	19
2.1.1	Recomendações quanto às dimensões de bagagens	19
2.1.2	Visão computacional e reconstrução de objetos 3D	20
2.1.3	Metrologia de termos utilizados nesse trabalho	21
2.1.4	Ferramentas para amostragem de point clouds	21
2.1.4.1	Sensores a laser fixos e móveis	22
2.1.4.2	Câmeras comuns (visão binocular)	24
2.1.4.3	Sensores de profundidade	24
2.1.5	Comparação entre tecnologias para atividades operacionais em terminais aeroportuários	26
2.1.6	Métodos e algoritmos comumente utilizados	28
2.1.6.1	Métodos para obtenção de dimensões	29
2.1.6.2	Métodos para Clusterização	32
2.2	Trabalhos relacionados	32
2.2.1	Abordagens principais e complementares	33
2.2.2	Quanto à forma e complexidade da bagagem sendo detectada	36
2.2.3	Sensibilidade ao posicionamento da bagagem	36
2.2.4	Pontos em aberto	37
3	Materiais e Métodos	39
3.1	Captura da <i>Point Cloud</i>	40
3.1.1	Modelagem da solução para captura da <i>point cloud</i>	41
3.1.2	Desenvolvimento do hardware e algoritmo de captura de dados	45
3.2	Processamento da <i>point cloud</i>	50
3.3	Pós-processamento	52
4	Resultados e Discussões	54
4.1	Resultados dos testes do protótipo	54
4.1.1	Testes com sensor em diferentes posições	54
4.1.2	Testes com malas em posição deitada	55
4.1.3	Testes com malas em posição de pé	56
4.1.4	Testes com malas em posição de lado	57
4.2	Discussão quanto aos resultados gerais	58

4.3	Simulação de operação do modelo proposto	58
5	Conclusão	62
Referências		64
Apêndices		71
APÊNDICE A	Códigos-fonte do sistema de medida de bagagens	72
APÊNDICE B	Interface de usuário	73

1 Introdução

De 2004 ao início de 2020, o número de pessoas utilizando o transporte aéreo chegou a 4,723 bilhões (STATISTA, 2020; ICAO, 2019). Por conta desse volume, a logística de embarque vem realizando um papel fundamental para mitigar atrasos em processos tais como *check-in* e verificação de bagagens (GAO; LIANG, 2021). No entanto, ao se comparar o tempo de embarque de 200 passageiros em 1990 e em 2009, vê-se um aumento de 22 minutos para 40 minutos, indicando que o processo de embarque continua sendo um fator que consome tempo razoável nos aeroportos (REN; ZHOU; XU, 2020). Isso destaca que é necessário evoluir as tecnologias aplicadas nesse setor, visto que, atrasos acabam resultando em prejuízos para os passageiros e para as companhias (REN; ZHOU; XU, 2020; AIRLINES, 2020; QINGJI; CHUANBO; QIJUN, 2018; GAO et al., 2018).

Dentro do processo de embarque, a verificação das dimensões de bagagens de mão é um dos fatores que consome tempo significativo (RONZANI; CORREIA, 2015; NEGRI; BORILLE, 2017). Outro fator é o congestionamento formado no corredor entre os assentos. Um dos motivos para tal problema decorre do atraso da armazenagem das bagagens pelos passageiros, ação influenciada pelas dimensões, quantidade e material das mesmas (REN; ZHOU; XU, 2020).

Para mitigar esse problema, as empresas aéreas investem em soluções automatizadas. Dentre essas, destaca-se a implantação de terminais de autoatendimento para acelerar o processo de embarque (COLBY, 2019; REN; ZHOU; XU, 2020). Tal procedimento, tem como requisito o uso de tecnologias que possibilitem ao passageiro fazer o seu próprio *check-in* e despacho de bagagens (*self bag drop*). Essa lógica, pode ser aplicada na entrada, na área de espera, ou disponível ao longo do aeroporto (ALSYOUF et al., 2018). Isso otimiza os serviços e aprimora a economia de tempo. Entretanto, o processo de verificação do dimensionamento da bagagem recai ao passageiro, que pode gerar erros devido ao formato ou posição da bagagem e a complexidade de lidar com múltiplos objetos despachados em conjunto (COLBY, 2019; REN; ZHOU; XU, 2020).

Uma das abordagens utilizadas por empresas aéreas para reduzir esses erros é o uso de equipamentos de visão computacional, que podem aprimorar a verificação e diminuir a necessidade de instrumentação do equipamento (ANDERSON, 2019; HUMPHRIES, 2019; KUCUK et al., 2019; GOCMEN, 2021). Tais dispositivos obtêm as dimensões pela aplicação de, por exemplo, processamento digital de imagens (PDI), reconstrução de objetos 3D e/ou aprendizado de máquina (ZHANG et al., 2018).

Para as companhias aéreas, o mais comum é o uso de sensores a LASER, capazes de obter informações das bagagens em forma de *point clouds* (nuvem de pontos) (GAO;

(LIANG, 2021). Os pontos representam amostras das extremidades de um objeto no espaço e, a partir dessa nuvem de pontos, pode-se obter a dimensão do objeto (CHEN et al., 2013). Os equipamentos que utilizam essa técnica podem retornar com precisão as dimensões das bagagens, contudo, estes equipamentos geralmente têm preços expressivos, variando de USD 10.000,00 a USD 111.000,00 dólares para um único sensor. Além disso, os mesmos comumente requerem uma instrumentação e modificação do ambiente para sua instalação, por vezes, inviabilizando a operabilidade em outros ambientes, como, por exemplo, utilizar tais dispositivos nas esteiras internas de despacho (WAN et al., 2012; GAO et al., 2018).

Dada a inflexibilidade dos equipamentos existentes, aliado aos preços expressivos, surge uma lacuna importante no setor, trazendo oportunidades para a experimentação de novas abordagens na construção de sistemas de visão com custos menores. Tais sistemas, vêm utilizando alternativas para coletar os dados de posição ou dimensões dos objetos do mundo físico como, por exemplo, câmeras digitais e sensores de profundidade (CHAN et al., 2018).

No que diz respeito aos sensores de profundidade, um exemplo relevante é o Microsoft Kinect, que tem se tornado popular devido ao seu preço consideravelmente mais baixo em comparação com os dispositivos de mercado, custando cerca de USD 200 dólares. Esse sensor é capaz de capturar os pontos que compõem a superfície de objetos no mundo físico, além de permitir o estudo de texturas e cores por meio de uma câmera RGB, o que possibilita a criação de *point clouds* coloridas. Devido à sua relevância para os objetivos desta pesquisa, optamos por utilizar esse sensor nos produtos desenvolvidos neste trabalho.

Como exposto ao longo do texto, existem oportunidades de aplicação de dispositivos de baixo custo nesse escopo, os quais podem reduzir gastos das empresas aéreas quanto ao tempo e recursos financeiros. Sendo assim, o objetivo do presente trabalho é investigar a viabilidade técnica de se utilizar dispositivos de baixo custo na obtenção das dimensões de bagagens aeroportuárias.

1.1 Justificativa

Os sistemas de medições de bagagens possuem diversos aspectos a serem observados. Da perspectiva dos funcionários, por exemplo, determinadas atividades consistem em verificar as dimensões de bagagens, seja manualmente as posicionando em um sensor. Estas ações repetitivas, podem ser automatizadas por *self bag drop*, garantindo padronização, velocidade, economia e autonomia do processo (ZHENG et al., 2018; NEETHU; ANOOP, 2015).

Nessa vertente, os equipamentos disponíveis no mercado geralmente têm custos expressivos. Estes, ainda podem apresentar limitações tal como o número, posição e formato das bagagens, além de necessitarem de instrumentação. Por conta disso, empresas podem

optar por manter determinadas atividades manuais, aumentando gastos financeiros e o risco de gerar atrasos no processo de *check-in*. Sendo assim, dispositivos de baixo custo focados em *self bag drop* podem contribuir com a qualidade do processo de embarque nessas empresas (GAO et al., 2018).

Outro aspecto a ser considerado é que um sistema que seja de fácil transposição pode facilitar o uso em diferentes locais do aeroporto, sem necessidade de alteração de infraestrutura. Esse aspecto também possibilita que esses sejam aplicados a diferentes normas vigentes no país, como, por exemplo, a verificação de bagagens de mão e de porão.

Desse modo, o avanço de pesquisas relacionadas ao desenvolvimento de sistemas de *self bag drop* de baixo custo faz-se necessário, uma vez que aumenta a qualidade de processos/produtos em aeroportos, reduz o tempo de embarque e possibilita que o passageiro verifique as dimensões de suas bagagens pessoalmente.

Por fim, é importante destacar que os conceitos explorados neste trabalho têm aplicações relevantes em diversas outras indústrias. Por exemplo, empresas do setor alimentício ou de transporte de cargas podem se beneficiar ao verificar as dimensões das caixas, garantir a qualidade dos alimentos e otimizar o espaço de seus produtos para melhorar a eficiência da logística de transporte (CHEN et al., 2013; GOMES; LETA, 2012).

1.2 Objetivos

O objetivo geral do presente trabalho é investigar a viabilidade técnica de se utilizar dispositivos de baixo custo na obtenção das dimensões de bagagens aeroportuárias.

Os objetivos específicos desta pesquisa se desdobram em:

- realizar um mapeamento e comparação dos dispositivos existentes para detecção de dimensões de bagagens;
- propor um modelo de sistema para obtenção de dimensões de bagagens de baixo custo, com uso de algoritmos de visão computacional e sensor de profundidade;
- avaliar o desempenho desta tecnologia quanto à posição do sensor;
- avaliar o desempenho desta tecnologia em lidar com diferentes posições e formas de bagagens.

1.3 Organização do Trabalho

O presente trabalho está organizado em cinco capítulos. No Capítulo 1 foram discutidas as informações introdutórias quanto à pesquisa, pontuando, também, as motivações e objetivos do trabalho. Já o Capítulo 2 corresponde ao referencial teórico, reunindo

informações quanto aos fundamentos que sustentam essa pesquisa, incluindo tecnologias, métodos e comparações, sendo que, em seguida, são discutidos os trabalhos relacionados, trazendo as abordagens principais e complementares, encerrando com os pontos em aberto. No Capítulo 3 são expostos os materiais e métodos, discorrendo sobre o modelo proposto para medida de bagagens e suas etapas de captura de dados, pré-processamento e pós-processamento. Na sequência, o Capítulo 4 traz os resultados e discussões quanto aos testes realizados com a solução proposta. Finalmente, no Capítulo 5 é realizada a conclusão, composta pelas considerações quanto aos resultados e o objetivo da pesquisa, encerrando com indicações para trabalhos futuros.

2 Referencial teórico

No presente capítulo, serão discutidas as teorias e trabalhos relacionados a essa pesquisa. Primeiramente, será feita uma breve revisão quanto aos conceitos que sustentam a teoria da pesquisa. Posteriormente serão discutidos os trabalhos relacionados, indicando os pontos principais e as lacunas de estudo identificadas.

Sendo assim, com o intuito de levantar as informações citadas e identificar quais são as tecnologias de baixo custo que podem ser empregadas para obtenção das dimensões de bagagens, foi realizada uma revisão sistemática. Para tanto, foram definidas questões de pesquisa cuja revisão buscava responder, sendo elas:

- Quais são as tecnologias que podem servir para detectar a dimensão de bagagens?
- As tecnologias conseguem analisar bagagens com formatos não retangulares?
- As tecnologias conseguem analisar múltiplas bagagens (ex. uma em cima da outra)?
- A exatidão das tecnologias é sensível ao posicionamento da bagagem?

Considerando as questões mencionadas e com o objetivo de garantir a padronização e a reproduzibilidade desta pesquisa, foi adotado o protocolo *Preferred Reporting Items for Systematic Reviews and Meta-Analyses* (PRISMA), como descrito em ([MOHER, 2009](#)). Esse protocolo inclui as etapas de identificação, triagem e inclusão. A Figura 1 ilustra os passos do método, juntamente com o número de artigos obtidos em cada etapa.

A primeira fase visa identificar os artigos na literatura. Para tal, é necessário definir uma base de dados, bem como a estratégia de busca. No presente trabalho, foram selecionadas as bases *Web of Science*, *Scopus* e *Google Scholar*.

Em sequência, foi realizado o refinamento da *string* de busca. Esta foi escolhida mediante testes nas bases e avaliações dos resultados obtidos. A *string* final é composta pela junção das seguintes palavras-chave:

- String de busca em inglês:
 - (*Baggage OR Luggage OR Backpack OR Airport*) AND
 - (*Volume OR Size OR Dimension*) AND
 - (*point cloud OR Points OR Convex Hull OR Volume Detection OR Kinect OR Reconstruction OR “Object measurement”*)
- String de busca em português:

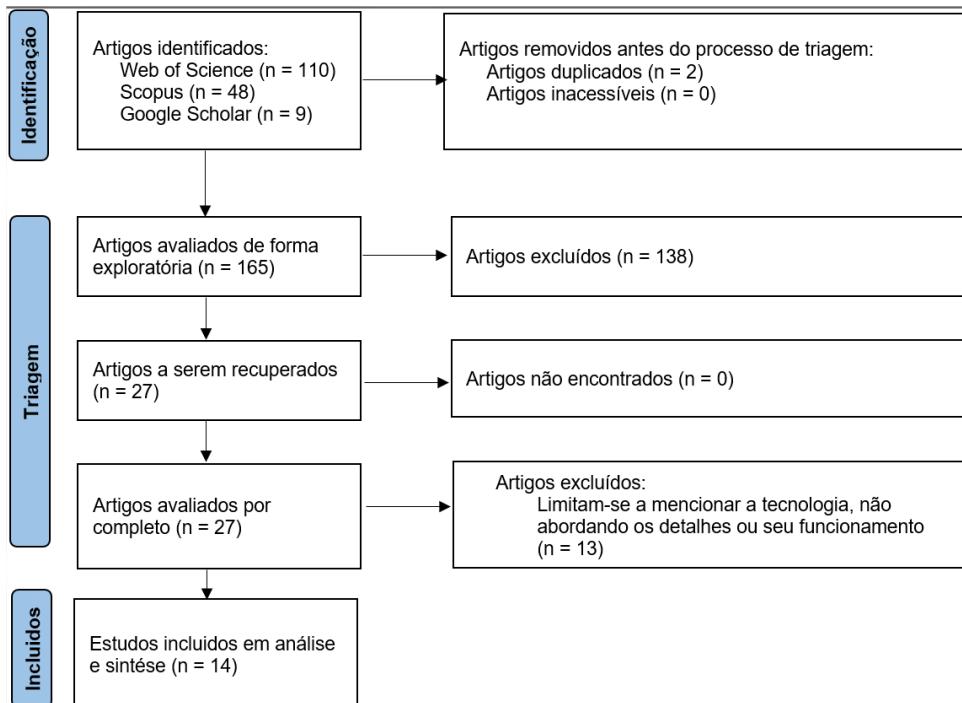


Figura 1 – Fluxograma da revisão sistemática conforme o protocolo PRISMA

- (*Bagagem OU Mochila OU Bolsa OU Aeroporto*) E
- (*Volume OU Tamanho OU Dimensão*) E
- (*Nuvem de pontos OU Pontos OU Fecho Convexo OU Detecção de Volume OU Kinect OU Reconstrução OU “Medida de Objetos”*)

A string direciona o alcance da revisão a trabalhos que lidam com bagagens, contudo, o uso do operador “ou” permite a ocorrência de artigos aplicados em outros contextos que exploram medida de dimensões. Sendo assim, foi possível identificar 167 trabalhos. Observa-se que não foi adotado um limite de tempo para a busca. Os trabalhos retornados nessa etapa avançaram para a triagem.

A etapa inicial da triagem consistiu em uma leitura exploratória dos trabalhos para compreender se os mesmos são coerentes com a temática almejada. Nesta etapa, os artigos foram selecionados pela leitura do título, abstract e palavras-chave. Para realizar esse filtro, foram definidos os seguintes critérios de exclusão:

1. Descartar trabalhos que se limitam a detectar a presença da bagagem, mas não aborda o aspecto de sua dimensão ou volume;
2. Descartar trabalhos que se limitam a detectar a presença de uma bagagem em situações isoladas, como em situações de segurança;

Com base nos critérios definidos, foi possível remover 138 dos 167 trabalhos. A próxima etapa consistiu em recuperar os 27 trabalhos selecionados. Na data da presente revisão, todos os trabalhos foram recuperados sem problemas de acesso.

Ainda no processo de triagem, realizou-se a leitura por completo dos trabalhos recuperados. Além dos critérios mencionados, descartaram-se trabalhos que apenas mencionam a detecção de dimensões, porém não entram em detalhes sobre os métodos ou tecnologias envolvidas. No final, foram incluídos 14 trabalhos. As próximas seções discorrem sobre os conceitos teóricos básicos e as informações obtidas por meio dos trabalhos selecionados.

2.1 Fundamentação teórica

A presente seção realiza uma breve revisão quanto aos conceitos que sustentam a teoria dessa pesquisa. Desse modo, serão discutidas as recomendações de dimensões para bagagens no Brasil, as ferramentas que podem ser utilizadas para extração das *point clouds* e os métodos comumente utilizados para processá-las.

2.1.1 Recomendações quanto às dimensões de bagagens

Para contextualizar o domínio de atuação desta pesquisa, é interessante considerar as recomendações quanto às dimensões das bagagens, especialmente na fase do check-in. É importante assinalar que o levantamento foi baseado na resolução nº 400 da agência Nacional de Aviação Civil ([ANAC, 2022](#)), mas podem ser customizadas pelas companhias aéreas. Por esse motivo, também foram consideradas empresas brasileiras, tal como [Azul \(2022\)](#) e a [Gol \(2022\)](#).

Prosseguindo, no check-in são apresentados os documentos necessários para embarque no voo, assim como, validação da bagagem de mão/porão. Por recomendação das companhias, isso deve ser feito com no mínimo 70 minutos de antecedência. Ao chegar no aeroporto, o passageiro terá que esperar pelo atendimento na fila de check-in, salvo se foi um processo remoto. Ainda nessa etapa também são despachadas as bagagens de porão e autorizadas as bagagens de mão, ambas mediante validação das medidas ([DENIS, 2021](#); [DANIEL, 2021](#)).

O processo discutido revela a importância do tempo que o fluxo requer. Isso indica que os equipamentos utilizados para essa etapa devem ter o mais baixo consumo de tempo possível, dado que, alguns minutos já poderiam fazer o passageiro perder o voo. Quanto às bagagens, essas podem ser classificadas em três categorias ([AZUL, 2022](#)):

- **Bagagens de mão:** são levadas para a cabine da aeronave pelo próprio passageiro. Cada passageiro pode levar até 1 unidade sem taxa extra. Segundo a ANAC, os

limites padrões para bagagens de mão são os seguintes: Altura: 55 cm; Largura: 25 cm; Profundidade: 35 cm e Peso máximo: 10 kg;

- **Bagagens de despacho:** devem ser entregues aos funcionários do aeroporto no balcão de check-in, ou para funcionários do despacho, a qual será enviada para o porão da aeronave. Cada passageiro pode levar até 1 unidade sem taxa extra. Segundo a ANAC, os limites padrões para bagagens de porão são os seguintes: Altura: 55 cm; largura: 80 cm; profundidade: 28 cm e Peso máximo: 23 kg.
- **Bagagens especiais:** São consideradas bagagens especiais aquelas que tem formato ou condição de manuseio diferentes do padrão (ex. malas de instrumentos, malas de itens de esporte), ou que estejam categorizadas como itens extras que não são contabilizados nas medidas (ex. tablet, notebook). Essa categoria é geralmente validada separadamente das demais malas. No caso, a Presente pesquisa não irá abordar em detalhes a medida desse tipo de mala.

É importante ter atenção às regras para dimensões e peso de bagagens estabelecidos pela companhia aérea contratada. Caso as malas excedam os limites, o passageiro terá que pagar uma taxa extra, caso contrário, poderá ser impedido de embarcar e orientado a realizar novamente o check-in.

2.1.2 Visão computacional e reconstrução de objetos 3D

Segundo [Zheng et al. \(2018\)](#) e [Neethu e Anoop \(2015\)](#), visão computacional é o processo de aquisição e análise de cenas reais (como vídeo e imagens) para tomada de decisões. O processamento das cenas, se dá por meio da aplicação de algoritmos de processamento digital de imagens, usados para extrair características e/ou tratar imagens. Por sua vez, tais características podem ser dados de entrada para modelos matemáticos, como, por exemplo, redes neurais. Ainda, segundo [Bhowmik e Appiah \(2018\)](#), esses sistemas seguem um fluxo padrão de etapas, envolvendo o uso de sensores para captura dos dados, posteriormente o processamento, extração das características e, por fim, classificação.

Quanto à reconstrução de objetos 3D, detalha-se que este é um ramo de estudo da visão computacional que visa reproduzir objetos do mundo físico no mundo digital, tendo, por sua vez, outros propósitos além da detecção das dimensões, tais como representar superfície e textura ([WARNETT et al., 2016](#); [CHEN et al., 2013](#)). Desse modo, existem duas vertentes, a reconstrução visual e a reconstrução ao nível de pontos. A presente pesquisa foca na segunda vertente, dado que a reconstrução é feita com intuito de obter-se as dimensões das bagagens, não sendo necessário realizar a reconstrução da superfície visual dos dados, conforme feito em trabalhos que focam em modelagem 3D.

2.1.3 Metrologia de termos utilizados nesse trabalho

A metrologia se dedica à pesquisa e à padronização dos procedimentos e terminologias relacionados a pesos e medidas. Neste trabalho, é importante ressaltar a definição adotada para algumas palavras frequentemente utilizadas ao descrever os resultados de testes. Essas palavras incluem "precisão, acurácia" e "exatidão". Para tanto, foi utilizado como base o vocabulário internacional de metrologia (VIM) presente em (INMETRO, 2022) dentre outras fontes a serem citadas ao longo do texto.

Prosseguindo, o termo *precisão* refere-se ao grau de variação dos valores obtidos em um conjunto de medição, isso é, se o erro-padrão entre as medidas tem resultados próximos. Já a *acurácia*, na presente pesquisa, se refere a proximidade do resultado medido ao valor tido como verdadeiro, significado semelhante ao de *exatidão*, que também se refere ao grau de concordância entre um valor medido e um valor verdadeiro. Os autores do presente trabalho optaram pelo uso do termo *exatidão*, uma vez que é definido em INMETRO (2022). Cabe destacar que, esses termos são qualitativos, por tanto, são necessários cálculos como erro absoluto médio (MAE) ou erro padrão para mensurar os valores (INMETRO, 2022; ZRHANS, 2018).

2.1.4 Ferramentas para amostragem de point clouds

Com base nos resultados da revisão sistemática, observou-se uma multiplicidade de tecnologias que podem ser utilizadas para captura das dimensões de bagagens. O mesmo raciocínio se aplica aos algoritmos para tratamento dos dados, seja na remoção de ruídos, seja na junção dos pontos a serem processados.

Dentro do conjunto de tecnologias de captura, destaca-se o uso dos *scanners a laser*, *fixos e móveis*, *câmeras binoculares* e *sensores de profundidade* (ex. Microsoft Kinect, Intel RealSense). A Figura 2 lista os dispositivos citados.

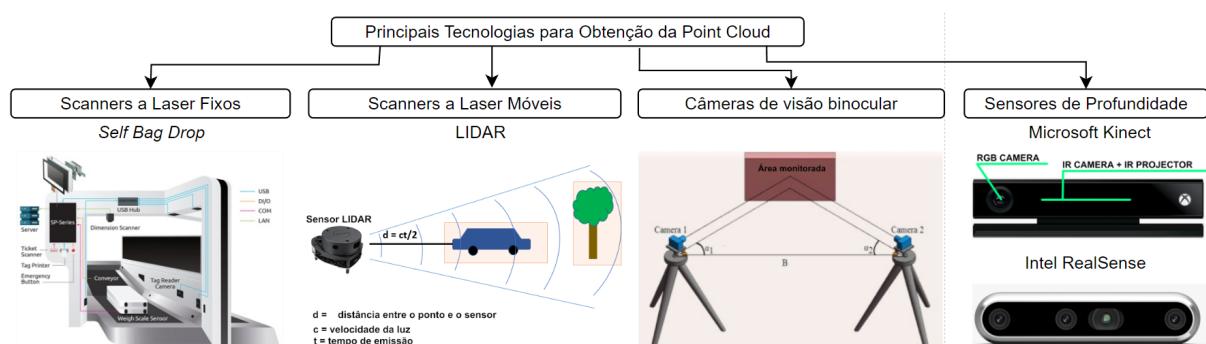


Figura 2 – Dispositivos para captura de *point clouds*

2.1.4.1 Sensores a laser fixos e móveis

Os métodos que utilizam scanners a laser seguem uma de duas abordagens. A primeira é movimentar o laser ao longo do objeto, como em uma impressora, a segunda é mover o objeto ao longo de um eixo. Nesse caso, são definidas a velocidade do objeto e a taxa de amostragem do sensor, a partir disso, o laser coleta amostras de secções do objeto em forma de pontos no plano. Ao final do processo, todos os planos são combinados para formar uma *point cloud* em terceira dimensão (GAO et al., 2018; HYYPÄ et al., 2020a). A Figura 3 ilustra a segunda abordagem, usando uma esteira para mover o objeto.

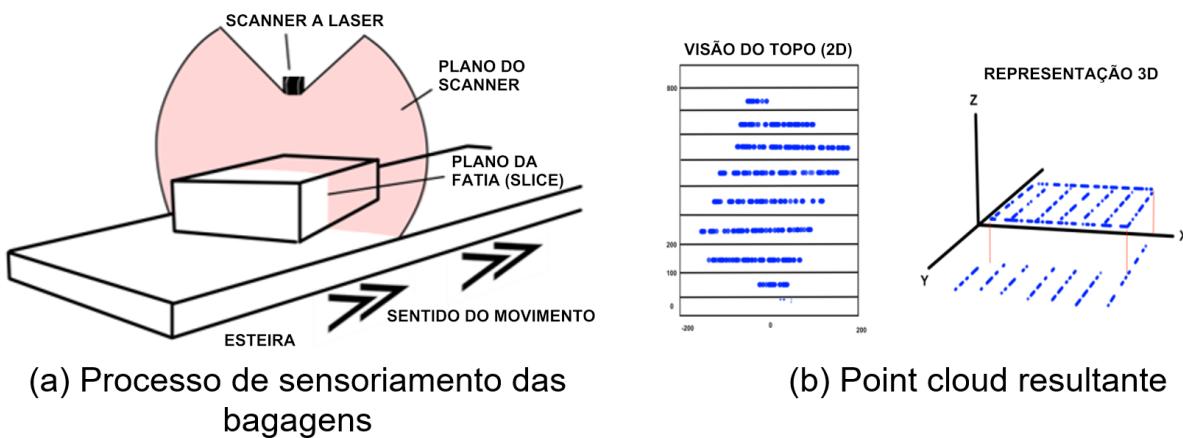


Figura 3 – Processo de obtenção de *point clouds* com scanner a laser

Quanto aos *Scanners a laser fixos* exemplificados nas Figuras 2 e 4, estes, dentro do tema abordado, são aplicados em serviços de autoatendimento (*self bag drop*). Tais equipamentos são compostos por uma esteira, um ambiente interno com lasers e uma central de processamento (QINGJI; CHUANBO; QIJUN, 2018). O cliente coloca sua bagagem na esteira e o scanner, pelo uso dos sensores, retorna os valores de dimensões e/ou informações quanto à segurança e peso da bagagem (GAO et al., 2018). Esses equipamentos são os mais utilizados no mercado, porém, eles têm alto custo, são de uso específico e não apresentam tratamentos para casos excepcionais onde o cliente não posiciona as malas da forma padrão (REN; ZHOU; XU, 2020; GAO; LIANG, 2021; QINGJI; CHUANBO; QIJUN, 2018).

Também cabe destacar dois pontos quanto ao posicionamento de *self bag drops* nas esteiras de atendimento, sendo eles o procedimento de uma etapa (*one-step*) e de duas etapas (*two-step* (NEALE, 2017)). O *one-step* consiste da integração da esteira de medida de bagagem e de despacho, com isso o passageiro precisa posicionar a bagagem apenas uma vez, o que é mais eficiente e cômodo. O *two-step* consiste em ter a esteira para medida de bagagens separada da de despacho. O passageiro precisa posicionar a bagagem primeiro no dispositivo para medida e depois transportá-la para a próxima etapa, é um processo com mais passos, porém, mais barato para a empresa.



Figura 4 – *self bag drop* de 10Hz e 40cm/s com Scanner URL-04LX ([GAO et al., 2018](#))

Avançando na discussão, os scanners a laser móveis, exemplificado na Figura 5, são aplicados no escaneamento de ambientes internos e externos ([ZHANG et al., 2018](#)). A diferença ao modo fixo é que um operador ou veículo carrega o scanner, caminhando pelo cenário de modo a circundar a área para captura da *point cloud* em 3D.

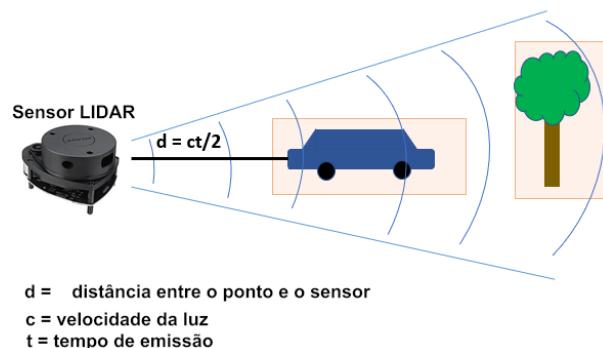


Figura 5 – Sensor LIDAR escaneando ambiente externo. Adaptado de ([MATHWORKS, 2022b](#))

Ao longo do processo, o equipamento recebe as informações dos sensores e converte em *point clouds*, que são tratadas pelo sistema interno de modo a eliminar valores atípicos (*outliers*) ([XU et al., 2021](#)). A partir disso, é possível reconstruir o ambiente explorado, seja com as funções do próprio equipamento, ou em softwares externos ([XU et al., 2021; ZHANG et al., 2018](#)). Para tanto, esses equipamentos geralmente utilizam sensores LiDAR (Detector de luz e espaço – *Light Detection and Ranging*) que consegue obter informações de pontos a longas distâncias ([ZHOU et al., 2019](#)).

2.1.4.2 Câmeras comuns (visão binocular)

Ainda quanto à geração da *point cloud*, é importante mencionar os dispositivos que fazem uso da visão binocular. Essa técnica se assemelha à visão humana, envolvendo a captura de duas imagens do mesmo objeto por meio de câmeras, em ângulos ligeiramente diferentes. Com base nessas imagens, é possível criar uma representação tridimensional do objeto e determinar suas dimensões (QINGJI; CHUANBO; QIJUN, 2018). A principal desvantagem desse método é a posição da mala, que pode afetar significativamente o resultado, por vezes tornando essa abordagem impraticável (GAO; YANG, 2013).

Os sistemas que empregam essa técnica podem utilizar um dispositivo de visão binocular dedicado ou apenas coletar duas imagens em ângulos pré-definidos. A disposição das câmeras deve permitir a visualização da largura e altura do objeto. Em seguida, um algoritmo de correspondência de pontos é executado. Este, seleciona um ponto entre às duas imagens (foco) e analisa. Essa análise pode ser baseada no método de combinação em escalas de cinza ou na combinação de características. O algoritmo rastreia as duas imagens, pixel a pixel, mapeando os pontos dos índices (x, y) do R2 em pontos (x, y, z) no R3 espaço em x, y e z (SUN; WANG, 2019; QINGJI; CHUANBO; QIJUN, 2018; LI; YANG, 2017). A Figura 6 mostra o modelo para captura de um ponto no espaço utilizando a técnica da visão binocular.

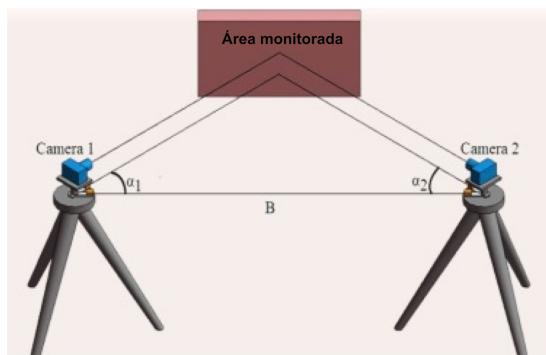


Figura 6 – Captura de um ponto com visão binocular. Adaptado de (HU et al., 2020)

2.1.4.3 Sensores de profundidade

Como alternativa para as tecnologias mencionadas, pesquisadores têm explorado os sensores de profundidade, como o Kinect e o *intel realsense* (RUCHAY; DOROFEEV; KOLPAKOV, 2018). O sensor kinect, inicialmente desenvolvido pela Microsoft para videogames (CHAN et al., 2018), tem demonstrado sua utilidade e eficiência em pesquisas científicas, sendo capaz de gerar *point clouds* com alta precisão e rapidez (CHEN et al., 2013). Além disso, seu baixo custo, em torno de 200 dólares, o torna uma opção viável para a criação de sistemas de visão de baixo custo (WAN et al., 2012). A Figura 7, representa um Kinect versão 2 e seus requisitos de hardware.



Figura 7 – Kinect V2

Quanto ao hardware, o Kinect é composto por três lentes. Duas dessas lentes funcionam como emissor e receptor de infravermelho, sendo responsáveis por capturar informações de profundidade da cena. A terceira lente é uma câmera RGB que opera a 30 quadros por segundo (fps), com resolução de 640x480 pixels na versão 1.0 e 1920x1080 pixels na versão 2.0. O Kinect 2.0 apresentou diversas melhorias, incluindo o aumento da resolução da câmera RGB e a correção de alguns problemas relacionados ao rastreamento de movimento ([CHAN et al., 2018](#); [RUCHAY; DOROFEEV; KOLPAKOV, 2018](#)).

Com isso, os principais elementos que podem ser capturados via Kinect v2 são uma imagem RGB, uma imagem de profundidade e a *point cloud*. A *colorImage* (imagem RGB) pode ser utilizada para colorir a *point cloud*, permitindo o estudo, por exemplo, de textura. A *depthImage* (imagem de profundidade) contém os dados de profundidade, largura e altura de cada ponto, dado que, devido ao alcance dos sensores IR, às dimensões são de 512 x 424.

Quanto ao alcance de captura do Kinect, este tem o limite máximo de 8 m e mínimo de 0,4 m. No entanto, a distância que retorna medidas mais precisas tem o máximo de 3 m e o mínimo de 0,5 m, a precisão de medição se altera conforme a distância do objeto partindo de 1 mm a 10 cm ([GUFFANTI et al., 2020](#)).

Avançado na discussão, outra opção de sensor de profundidade é o *intel realsense*, distribuído em vários modelos. Considerando a linha D400 no modelo D450, tem-se que a resolução da câmera de profundidade é de 1280 x 720 com até 90 fps, sendo o espaço de alcance de 0,6 m até 6 m e 2% de precisão. Já a câmera RGB tem 1280 x 800 pixels de resolução com até 30 fps, equivalente ao do kinect v2 ([INTEL, 2021](#)).

A técnica de captura utilizada pelos sensores de profundidade envolve a emissão de um raio infravermelho que, ao entrar em contato com um objeto, é refletido de volta e capturado pelo receptor. O sistema interno recebe essa informação e constrói um ponto no espaço (x, y e z). Esse processo é repetido ao longo dos limites do campo de visão do dispositivo, resultando em uma matriz de profundidade (*depth image*), com todos os

pontos em unidades de metros (m). Ainda, é possível obter uma *point cloud* colorida, gerada a partir do mapeamento dos pixels da imagem RGB (*color image*) nos pontos da imagem de profundidade (MATHWORKS, 2017; JIAO et al., 2017). A Figura 8 mostra um processo genérico para coleta de *point cloud* de um objeto utilizando um sensor de profundidade.

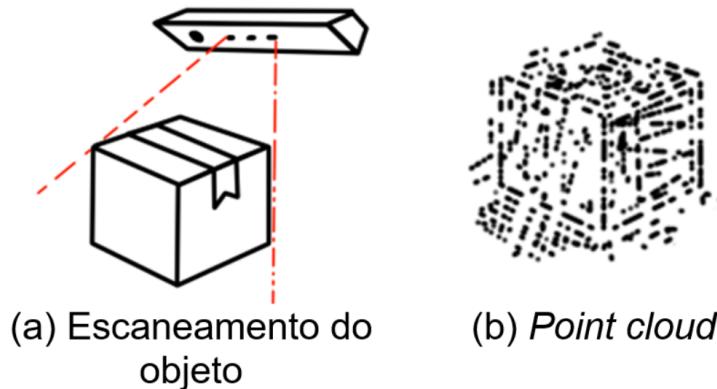


Figura 8 – Processo de obtenção da *point cloud* usando um sensor de profundidade

2.1.5 Comparação entre tecnologias para atividades operacionais em terminais aeroportuários

Na presente seção será realizada uma comparação entre as soluções retornadas pela revisão e outras tecnologias. Para tanto, foi utilizada a metodologia proposta por RONZANI et al. (2019), que estabelece uma abordagem para medição de desempenho entre tecnologias de monitoramento operacional em terminais aeroportuários. Nessa abordagem, cada elemento é avaliado com base em Indicadores de Performance Chave (KPI - *Key Performance Indicators*), critérios que permitem avaliar as tecnologias de forma agrupada, independente de sua aplicação no aeroporto. Por meio desses critérios é possível avaliar fatores gerais e de automação proporcionada pelo equipamento. Os principais KPIs propostos pela pesquisa citada e aqui utilizados, são os seguintes:

1. Precisão: capacidade de capturar corretamente os dados de interesse;
2. Automação: equipamentos que exigem operação pelo passageiro, estão mais suscetíveis a interferências no fluxo;
3. Confiabilidade: quanto maior a participação de indivíduos, mais suscetível a erros ou falhas o sistema é. Os equipamentos eletrônicos operam com pouco ou nenhum efeito humano no controle, agilizando, também, a correção de erros;
4. Segurança: se refere a segurança em se utilizar o equipamento, pode ser avaliada por meio de questionamentos tais como: A tecnologia lê a bagagem? A tecnologia

encontra as dimensões? É confiável que o passageiro vai pegar a mala de volta após passar pelo equipamento? É seguro utilizar essa tecnologia?;

5. Custo/tempo de implantação: se refere ao custo do equipamento e o tempo para integração da nova tecnologias nas dependências do aeroporto;
6. Custo de operação e manutenção: se refere ao custo envolvido na utilização do equipamento, por exemplo, se ele é totalmente automatizado, então o custo é menor com funcionários. O custo de manutenção tem relação com os ajustes necessários e os gastos para manter o dispositivo funcional e com peças adequadas.

A partir dos KPIs o método propõe a comparação entre as tecnologias por meio de uma tabela de multicritérios ponderados. São atribuídos pesos de 1 a 3, sendo 1 uma avaliação ruim, 2 uma avaliação regular e 3 uma avaliação boa. Com base nisso, foi gerada a Tabela 1 que faz a comparação relativa entre as tecnologias levantadas na revisão sistemática e algumas fora do escopo desse trabalho, mas indicadas em (RONZANI et al., 2019). A Figura 9 expõe os dados de forma gráfica, comparando os resultados para cada KPI individualmente.

ID	Tecnologia	Precisão	Automação	Confiabilidade	segurança	Custo e tempo de implantação	Custo de operação e manutenção
1	Sensores de profundidade	2	3	2	3	3	3
2	Câmeras Comuns (Visão binocular)	2	2	3	3	3	3
3	Scanner a laser fixo	3	3	3	3	1	1
4	Scanner a laser móvel	2	1	2	2	1	1
5	Leitor de QR Code	3	1	1	3	2	3
6	RFID	3	2	2	3	2	3
7	Sensores Estereoscópicos 3D	2	3	2	3	1	2
8	Contador infravermelho	2	3	2	2	2	2

Tabela 1 – Avaliação relativa entre as soluções levantadas nessa pesquisa e demais soluções tecnológicas (adaptado de (RONZANI et al., 2019))

Pela observação dos dados expostos na Tabela 1 e na Figura 9 é possível realizar algumas pontuações. Quanto à precisão, tem-se que as tecnologias 3, 5 e 6 obtiveram avaliação boa, já as demais soluções ficaram regulares. As tecnologias 1, 2, 3 e 7 tiveram, em média, boa avaliação em automação, confiabilidade e segurança, isso porque elas têm pouca ou nenhuma necessidade de intervenção humana no processo e, consequentemente, retornam resultados mais confiáveis, promovendo a segurança das bagagens já que existe pouca manipulação humana e, por vezes, o passageiro consegue acompanhar visualmente o processo. Por fim, as tecnologias 1 e 2 receberam boa avaliação em custos e tempo envolvidos na implantação, operação e manutenção, isso por que esses equipamentos têm boa usabilidade e peças de baixo custo.

Prosseguindo, a Tabela 1 mostra que as tecnologias para medida de bagagens, no caso o Scanner a laser fixo, câmeras comuns e sensores de profundidade, ficaram bem

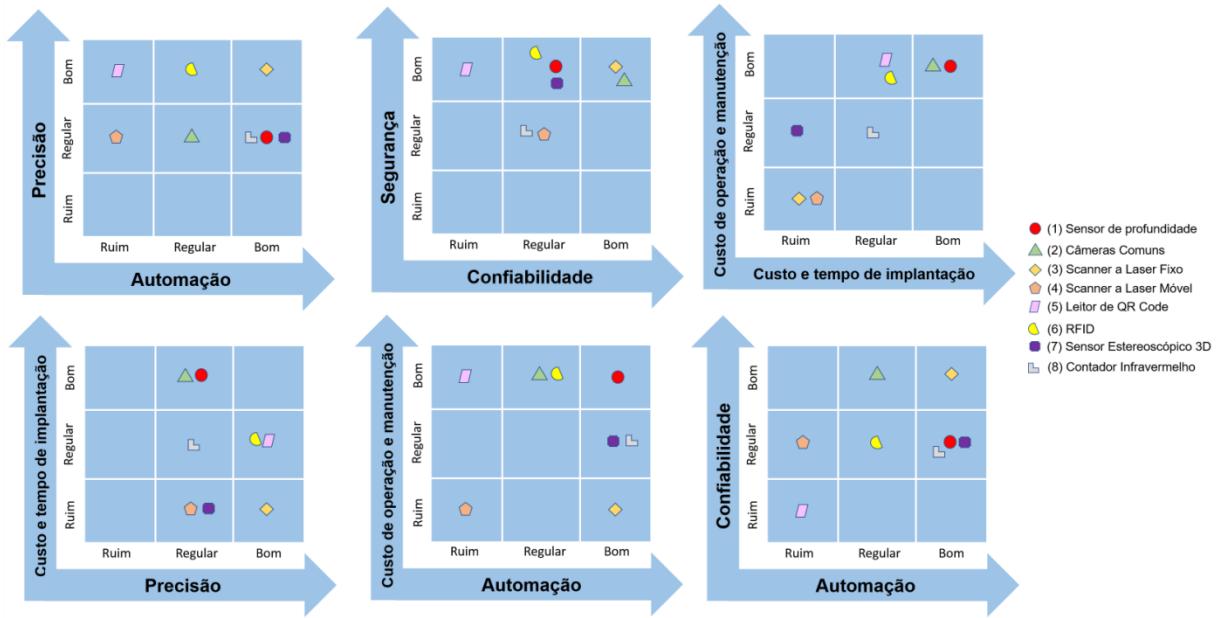


Figura 9 – Gráficos de comparação relativa entre as soluções levantadas e outras do mercado

próximos. Nesse contexto, a empresa precisa avaliar o custo-benefício da tecnologia e decidir qual equipamento utilizar em sua aplicação no aeroporto.

Nessa situação, outros fatores que podem ser considerados na aquisição de uma solução automatizada em detrimento de uma manual são a disponibilidade dos dados, detalhamento de padrões e subsídio a gestão comercial e operacional. Quanto à disponibilidade dos dados, sistemas manuais exigem mais tempo, já os automáticos fazem isso em segundos. Quanto ao detalhamento de padrões, os fatores humanos podem influenciar os resultados de cada aferição, em contrapartida, os sistemas automáticos reproduzem padrões no método e nos resultados. Por fim, quanto ao subsídio da gestão comercial e operacional, os sistemas automatizados podem coletar dados mais completos e precisos, possibilitando que gestores produzam análises mais aprofundadas.

2.1.6 Métodos e algoritmos comumente utilizados

De modo geral, as tecnologias utilizadas pela indústria aplicam técnicas de visão computacional e reconstrução de objetos 3D para obter a dimensão de objetos. Esse processo é feito tipicamente a partir de uma *point cloud* (nuvem de pontos), coletada via sensor. Esta, é um conjunto de informações representadas por pontos no plano ou no espaço. No presente trabalho esses pontos representam a superfície de uma bagagem em 3D (CHEN et al., 2013).

Posteriormente, os pontos podem ser delimitados em um polígono tridimensional para cálculo de dimensões. A literatura indica que é comumente empregado o algoritmo

de *convex hull* (fecho convexo) para obtenção do menor polígono que envolve os pontos do objeto capturado (NEETHU; ANOOP, 2015; GAO et al., 2018; DING et al., 2018).

Antes da análise da *point cloud*, são usualmente executados algoritmos de pré-processamento. Em tal etapa podem ser aplicadas técnicas tais como *subamostragem*, *clusterização* e os filtros de *média*, *bilateral* e *Gaussiano*. A subamostragem reduz a densidade de pontos, diminuindo o gasto computacional (RUCHAY; DOROFEEV; KOLPAKOV, 2018). Já a clusterização, remove *outliers* que podem atrapalhar o processo de reconstrução, por exemplo, um ponto extremo pode mudar significativamente o polígono que delimita o objeto 3D. Métodos dessa categoria possibilitam, também, agrupar informações semelhantes, o que pode acelerar o processamento das etapas posteriores. DBSCAN (Seção 2.1.6.2) e k-means são exemplos de algoritmos nesse escopo (LIMWATTANAPIBOOL; ARCH-INT, 2017).

Da mesma forma podem ser aplicados filtros para normalizar pontos e ressaltar saliências, como bordas das bagagens (RUCHAY; DOROFEEV; KOLPAKOV, 2018). Os Filtros bilateral e Gaussiano, reduzem erros de granulação nos cantos e de componentes de alta frequência (SHIN; HO, 2014; WAN et al., 2012). As próximas subseções entram em detalhes quanto aos métodos aplicados na presente pesquisa.

2.1.6.1 Métodos para obtenção de dimensões

Para manipulação da *point cloud*, comumente se utilizam os algoritmos de fecho convexo (*convex hull*) (DING et al., 2018). Dado um conjunto de pontos A, estes algoritmos operam de modo a encontrar os pontos da extremidade gerando um subconjunto B, que, por sua vez, representa o menor polígono que reveste todos os pontos da *point cloud* (ZHAO et al., 2018). Tal polígono, ou polígonos, podem ser utilizados para reproduzir a superfície dos objetos ou coletar informações de dimensões. A Figura 10 ilustra a aplicação do algoritmo citado em 2D e 3D.

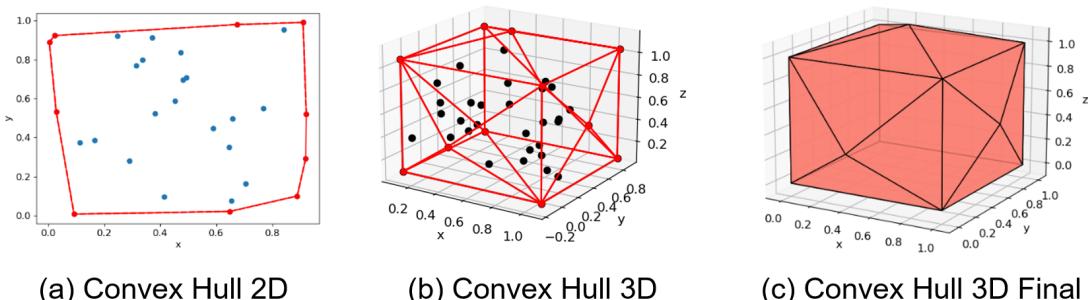


Figura 10 – Aplicação convex hull em 2D e 3D

No plano (2D), o convex hull é o menor polígono que contém um conjunto de pontos P . Já no espaço (3D), o convex hull é a menor figura tridimensional que reveste o conjunto de pontos P . A Figura 10 ilustra o resultado para ambas as situações citadas.

Outro detalhe, é que o convex hull 3D representa todas as combinações ou concatenação de conjuntos P_x de pontos no plano 2D extraídos do conjunto P_y de pontos no espaço 3D. Isso implica que ele é construído por meio da repetição do convex hull 2D em todo o conjunto de P_x pontos disponíveis, sendo que o conjunto resultante P_y , consequentemente, contém o conjunto P_x (ZHAO et al., 2018; LAURINI, 2017).

Avançando no tópico, outra opção para obtenção de dimensões são os algoritmos de caixas mínimas limitantes (*minimum bounding box* – MBB). Assim como o convex hull, que simplifica a forma original do objeto, esses algoritmos consideram qualquer forma como uma caixa. Nesse contexto, o objetivo é encontrar a figura retangular de menor área que envolve um conjunto P de pontos. Para tanto, são rastreados os limites da *point cloud* de modo a identificar os maiores e menores valores de x, y e z (SIWEI; BAOLONG, 2021). Essa abordagem é interessante, pois a partir desse polígono é possível extrair informações de largura, comprimento e profundidade, com boa exatidão e sem a necessidade de tratar todos os pontos do conjunto (ACTORSFIT, 2021).

Na literatura são identificadas muitas variações do MBB, sendo as principais o de caixas mínimas alinhadas com os eixos (*Aligned Axis Bounding Box* – AABB) e caixas mínimas orientadas (*Oriented Minimum Bounding Box* – OMBB). A Figura 11 ilustra os métodos citados assim como a aplicação em três dimensões.

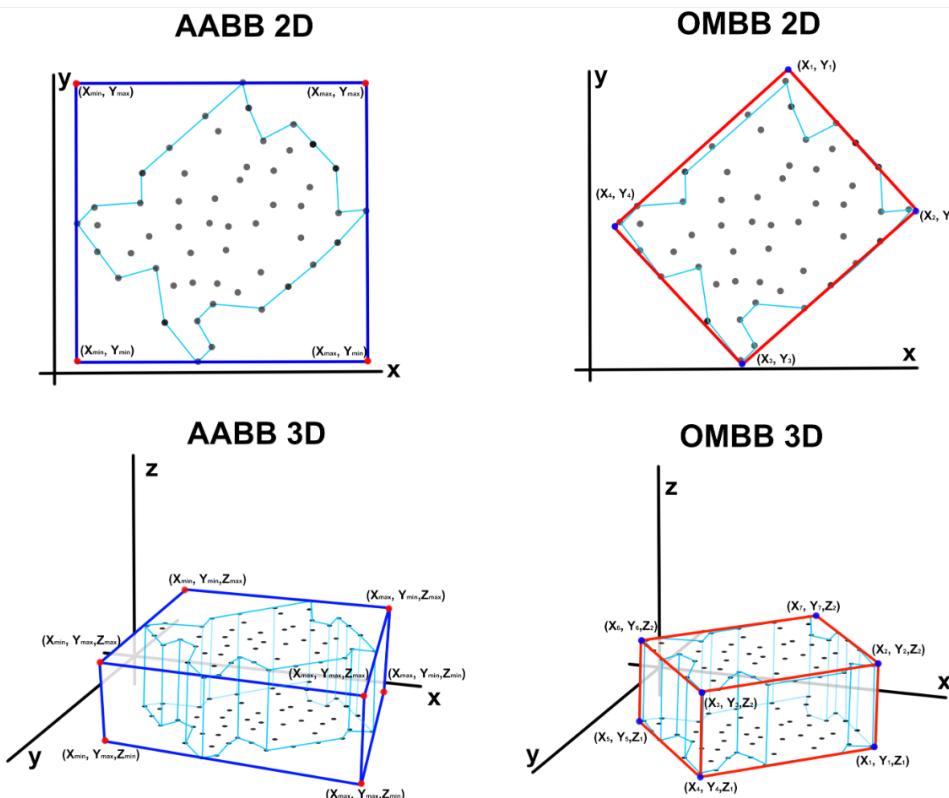


Figura 11 – AABB e OMBB 2D e 3D, convex hull em azul-claro. Adaptado de (DAVID, 2014)

Segundo Siwei e Baolong (2021) o AABB é o método mais simples dessa categoria e promove um processamento rápido. Neste caso, dada uma *point cloud*, são computados os pontos localizados nas extremidades máximas e mínimas considerando apenas os eixos do plano, sem avaliar se o objeto está rotacionado. Tais pontos representam os vértices de um retângulo que engloba a *point cloud*. Os módulos dos vetores traçados entre os pontos correspondem aos escalares das dimensões.

Já o OMBB é definido como o menor retângulo que engloba os pontos, podendo este estar em posição arbitrária em relação aos eixos. Esse método é mais complexo que o AABB, no entanto, é mais preciso, uma vez que consegue obter a menor medida considerando a orientação dos pontos (SIWEI; BAOLONG, 2021). Para medida de bagagens, esse método pode aumentar a exatidão do sistema em casos que a mala seja posicionada de outras formas que não a padrão (ex. rotacionada na diagonal). Uma das abordagens para obter o OMBB pode ser resumida nos passos ilustrados na Figura 12 (DAVID, 2014).

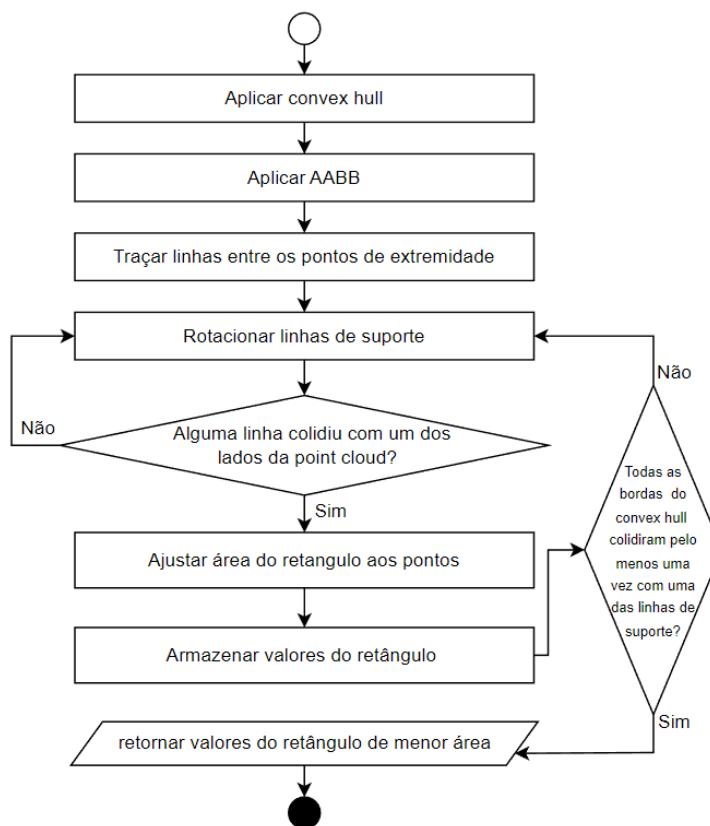


Figura 12 – Fluxograma OMBB. Adaptado de (DAVID, 2014)

Os métodos supracitados também podem ser aplicados em 3D. Uma abordagem para obter esse resultado é dividir o cenário 3D em vários casos de pontos em 2D. Desse modo é possível aplicar o AABB ou o OMBB nos N planos resultantes da divisão. Uma forma de dividir o cenário é processar uma face do cuboide por vez aplicando os processos nos planos (xy, xz, yz), ou segmentar os pontos em N planos em níveis diferentes do eixo Z (SIWEI; BAOLONG, 2021; MOUSAVIAN et al., 2017).

2.1.6.2 Métodos para Clusterização

O DBSCAN é um método de agrupamento de pontos em clusters, sendo o principal identificado na literatura no presente escopo. O algoritmo busca encontrar áreas de grande densidade de pontos que estão separadas por áreas com baixa densidade para as agrupar, formando assim, clusters (conjuntos) (SCHUBERT et al., 2017; HARMAN, 2020). É possível utilizar tal método para segmentação de imagens ou de pontos, filtragem, classificação de objetos e remoção de ruídos. Para tanto, o algoritmo rastreia os pontos classificando-os em uma de três opções, as quais são:

- **Pontos de núcleo (Core points):** são pontos que tem uma vizinhança grande o suficiente para formar um cluster, isso é dado pelo valor de “pontos mínimos”;
- **Pontos de borda (Border Points):** são pontos que não têm os pontos mínimos para formar um cluster, porém fazem parte do cluster de algum ponto de núcleo;
- **Pontos de ruído:** são pontos que não têm uma vizinhança grande o suficiente para formar um cluster e também não fazem parte de algum outro cluster.

Para realização da classificação, o DBSCAN trabalha com 3 parâmetros, mostrados na Figura 13, sendo eles os seguintes:

- ϵ : se refere ao tamanho do raio de um cluster. Ou seja, os clusters podem ser representados visualmente como um círculo de raio ϵ . Pelo cálculo da distância, se um ponto P_i de P estiver no raio ϵ de um conjunto A , ele faz parte deste conjunto;
- **MinPts:** é a quantidade mínima de pontos necessários dentro do alcance de ϵ para ser considerado um cluster;
- **Vizinhança:** a vizinhança de um ponto P_i é dada pela distância limitada pelo valor de ϵ .

A partir da teoria descrita, é possível perceber que o DBSCAN pode ser aplicado para diversos fins. Ele é capaz de separar vários conjuntos de pontos em clusters, independentemente do formato da *point cloud* e mesmo que esses conjuntos estejam distantes uns dos outros. Além disso, o DBSCAN pode ser utilizado como um filtro para remover *outliers*, identificando não apenas pontos de borda, mas também pontos que estão isolados do cluster principal.

2.2 Trabalhos relacionados

Assim como indicado na Figura 1, foram analisadas as abordagens dos trabalhos selecionados. A Tabela 2 sintetiza as principais características de tais trabalhos conforme o

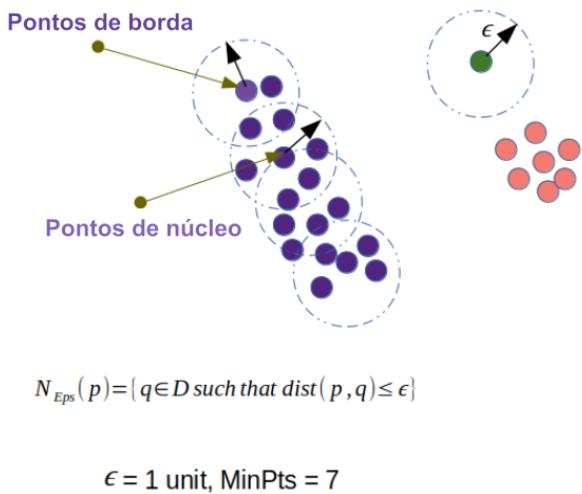


Figura 13 – Classificação dos pontos e definição dos clusters em uma *point cloud* (DBSCAN) (HARMAN, 2020)

tipo de objeto. Observou-se que todos os artigos analisados operam utilizando *point clouds*. O que os difere é como os mesmos a obtêm, bem como quais técnicas são empregadas para extrair as medidas dos objetos.

2.2.1 Abordagens principais e complementares

Tomando como referência a Tabela 2, os três primeiros trabalhos realizaram a detecção de dimensões de bagagens em aeroportos. Os demais, atuaram em outros contextos, os quais serão analisados segundo a aplicabilidade no problema em questão. A seguir são discutidas de forma pontual as informações obtidas.

Trabalho	Tecnologia base	Tipo de Objeto	Mult. objetos	Complexidade do objeto	Posição do Objeto
Gao et al. (2018)	Scanner a laser	Bagagens	Não	Uniforme	Limitado
Qingji, Chuango e Qijun (2018)	Câmera estereoscópica binocular HD e projetor	Bagagens	Não	Uniforme	Limitado
Gao e Yang (2013)	Duas câmeras com as mesmas especificações	Bagagens	Não	Deformações leves	Limitado
Ozbay e Cinar (2013)	1 Microsoft Kinect	Mobiliário, copos e cadeiras	Não	Uniformes e Curvos	Qualquer posição
Chen et al. (2013)	1 Microsoft Kinect	Caixas e obj. complexos	Não	Deformações grandes	Limitado
Ruchay, Dorofeev e Kolpakov (2018)	4 Microsoft Kinect	Genérico, teste com cadeira	Não	Uniformes e Curvos	Qualquer posição
Wan et al. (2012)	1 Microsoft Kinect	Genérico, teste com pessoas	Não	Deformações grandes	Limitado
Shin e Ho (2014)	2 Microsoft Kinect	Genérico, teste com pessoas e móveis	Não	Deformações grandes	Qualquer posição
Sun e Wang (2019)	1 Microsoft Kinect v2	Genérico, teste com árvore	Não	Deformações grandes com Lacunas	Limitado
Chan et al. (2018)	1 Microsoft Kinect v2	Alimentos	Não	Curvos	Limitado
Ryu et al. (2020)	Scanner a laser	Ambiente interno (ex. sala e paredes)	Sim	Uniforme	Qualquer posição
Hyyppä et al. (2020b)	Sensor a laser móvel	Obj. Complexos (árvores)	Sim	Curvos e Lacunas	Qualquer posição
Warnett et al. (2016)	Raio-X CT e Scanner a Laser	Produto em metal	Não	Uniformes e Curvos	Qualquer posição
Zhou et al. (2019)	Scanner a Laser Móvel	Obj. Complexos (árvores)	Sim	Deformações grandes	Qualquer posição

Tabela 2 – Comparaçāo entre as tecnologias dos trabalhos selecionados na revisão sistemática

Foram retornados no total 167 trabalhos, restando na fase final 14 trabalhos que atuam na obtenção de dimensões de objetos. De tais trabalhos, apenas 3 realizaram

deteção de dimensões de bagagens aeroportuárias. Os demais atuaram em outros contextos envolvendo extração de dimensões de objetos (ex. utensílios). 7 utilizaram Kinect para extração dos dados, que não foi o caso dos 3 trabalhos das bagagens. 4 utilizaram scanners a laser e 3 utilizaram visão binocular.

O trabalho de [Gao et al. \(2018\)](#) desenvolveu um método para coleta de dimensões das bagagens utilizando uma abordagem de caixas mínimas. Após a obtenção da *point cloud*, realiza-se uma etapa de regressão linear nos pontos com intuito de remover outliers para melhorar a precisão do cálculo, dentre elas as informações de alça. Apesar disso, observaram-se algumas limitações. A primeira é quanto a regressão linear, que por remover as alças, poderia diminuir a precisão do método em casos que a alça é fixa ou o formato da bagagem faça o algoritmo recortar um pedaço da mala (ex. instrumentos musicais). Na medida também são desconsideradas as rodas da mala, que segundo as normas da ANS devem ser consideradas para medidas. Além disso, caso exista uma deformação oclusa, o sistema retornará um dado errôneo. Por fim, destaca-se a limitação em utilizar somente uma bagagem por vez, dado que duas ou mais podem gerar erros.

O trabalho de [Qingji, Chuanbo e Qijun \(2018\)](#) utilizou a visão binocular para obtenção das dimensões das bagagens. O sistema proposto aplicou o método *Semi-Global Matching* (SGM) para encontrar os pontos em comum entre duas imagens, possibilitando assim a construção da *point cloud*. Os resultados obtidos sugerem uma alta precisão, obtendo um erro relativo máximo de 0,62%. Entretanto, ressalta-se a sensibilidade do método, uma vez que requer que as malas estejam obrigatoriamente em posição oblíqua em relação à câmera, além de processar somente uma bagagem por vez. Tais limitações dificultam a implementação do sistema para *self bag drop*, uma vez que o passageiro pode posicionar a bagagem de várias maneiras.

De forma semelhante, [Gao e Yang \(2013\)](#) utilizou a visão binocular para obter dimensões das bagagens. A diferença com a outra abordagem situa-se no método para obtenção da *point cloud*, no caso, utilizou-se o filtro de detecção de bordas (*canny edge*) e *stereo matching*. Com base nos testes de duas malas em formato cuboide, os resultados mostraram as mesmas limitações do trabalho anterior, ou seja, a posição da mala, obrigatoriamente em posição oblíqua e o limite de uma mala por vez.

Os demais trabalhos, aplicaram técnicas para detecção de dimensões de objetos em outros domínios, não relacionados à temática aeroportuária. Contudo, acredita-se que seus métodos podem ser adaptados para o problema das bagagens, uma vez que se pode alterar o objeto em análise.

Dentre esses trabalhos, 7 optaram por utilizar o sensor Microsoft Kinect para obtenção das dimensões dos objetos. Por exemplo, [Ozbay e Cinar \(2013\)](#) analisaram a viabilidade de se utilizar tal sensor para obtenção das dimensões de objetos do cotidiano, como canecas e estojos. O procedimento realizado utilizou o Kinect para escanear uma face

do objeto (180°). Tal abordagem, possibilita o cálculo da dimensão do objeto a partir do espelhamento da *point cloud* retornada. Entretanto, isso pode levar a um cálculo errôneo em objetos que possuem oclusão. [Ruchay, Dorofeev e Kolpakov \(2018\)](#) resolveram esse problema utilizando quatro sensores com intuito de remover *outliers* e alinhar os pontos obtidos. Outra estratégia alternativa foi a relatada por [Wan et al. \(2012\)](#), que requer que um operador humano move o sensor para a outra face. Entretanto, ressalta-se que tal procedimento é desvantajoso, pois requer uma intervenção humana no sistema.

Em essência, os resultados obtidos com uso de múltiplos Kinects, sugerem que é possível evitar perdas de dados ao lidar com malas de formatos complexos. Isso é possível, uma vez que a captura das informações é feita em múltiplos pontos de vista [Shin e Ho \(2014\)](#). Ainda assim, destaca-se que os métodos expostos requerem etapas pré-processamento, para alinhamento das *point clouds* e remoção de *outliers* (Ex. subamostragem, clusterização ou filtragem).

Outros estudos exploraram soluções para problemas inerentes a objetos com deformações grandes, lacunas ou curvos. Utilizando dois sensores, Kinects, [Shin e Ho \(2014\)](#) conseguiram computar a dimensão de uma pessoa. Para tal, é feito alinhamento e junção (*warping*) das *point clouds*. Os resultados sugerem que o sistema conseguiu reconstruir o objeto com boa precisão, restando algumas lacunas de dados perdidos, devido a reflexos ou movimentos. Complementarmente, [Sun e Wang \(2019\)](#) utilizaram um sensor Kinect para coletar a dimensão de objetos com lacunas, por meio da rotação do objeto perante o sensor. Estudos semelhantes foram feitos por [Chan et al. \(2018\)](#), que investigaram objetos curvos.

Destaca-se que uma parte dos estudos analisados almejaram a obtenção da dimensão de múltiplos objetos em simultâneo. [Ryu et al. \(2020\)](#) implementaram um sistema com scanner a laser móvel, para reconstrução de ambientes internos, onde é coletada a *point cloud* de corredores, aplicado um método para separar e agrupar os objetos identificando concentrações de pontos alinhados, para separá-los em teto, piso e paredes. Os resultados sugerem um erro de 16,3 mm a cada 2,3 m.

Os erros gerados nos estudos destacados não inviabilizam a adoção dos mesmos métodos adaptados a questão das bagagens. Isso pode ser observado em [Warnett et al. \(2016\)](#), onde foram realizados testes para comparação entre um scanner a laser fixo de aeroportos (*self-service*) e um dispositivo de tomografia computacional (CT). Enquanto o primeiro coleta *point clouds* em 180° , o segundo é mais preciso e coleta dados em 360° .

Os trabalhos supracitados demonstram a possibilidade de analisar as curvaturas da superfície de objetos de diferentes formatos. Isto permitiria aprimorar resultados com bagagens em formatos não cuboides, bem como realizar sua classificação (oval, cuboide, paralelepípedo entre outros).

2.2.2 Quanto à forma e complexidade da bagagem sendo detectada

A forma, posição e complexidade do objeto, pode aumentar significativamente os erros na detecção das dimensões. Os trabalhos analisados lidam com diferentes formatos de objetos, tais como cuboides e curvos. Com intuito de compreender o impacto da forma do objeto no método, decidiu-se classificar os objetos nas seguintes categorias:

- *Uniforme*: são objetos em formato cuboide (e.g., malas e caixas);
- *Deformações leves*: são objetos cuboides com cantos amassados que provocam pouca oclusão (e.g., malas de material firme, malas com alça);
- *Deformações grandes*: são objetos que podem ter formatos aleatórios e possuem oclusão (e.g., sacolas, cadeiras);
- *Curvos*: são objetos com formato oval ou circular, geralmente simétricos, que provocam erros se o método é de quadrados mínimos (e.g., malas redondas, esferas);
- *Lacunas*: são objetos que apresentam espaços vazios onde a ação do sensor não é refletida, provocando perda de informações (e.g., malas de instrumentos musicais);

Em objetos de formas uniformes, como malas cuboides, geralmente se tem resultados satisfatórios duplicando/espelhando a *point cloud* e suavizando os pontos utilizando o método dos mínimos quadrados. No entanto, quando o objeto é curvo ou tem deformações leves, é mais confiável realizar uma análise de 360° na *point cloud*, pois isso pode melhorar os resultados, especialmente se considerar a análise da curvatura do objeto. Para os casos de objetos com deformações grandes ou lacunas, a obtenção de múltiplas *points clouds* de faces opostas produz um resultado com maior fidelidade à forma do objeto, permitindo aplicações mais seguras do que os métodos baseados em duplicação.

Devido à possibilidade de posicionar duas ou mais malas simultaneamente durante a medição, seja de forma conjunta ou próxima uma da outra, o processamento de múltiplos objetos se torna importante no contexto de *self services*. Nesse cenário, os algoritmos destinados à medição de bagagens aqui analisados, poderiam interpretar erroneamente duas ou mais malas como uma unidade, levando a resultados imprecisos que poderiam inviabilizar a medição. A Figura 14 ilustra tais cenários.

2.2.3 Sensibilidade ao posicionamento da bagagem

Como analisado nos trabalhos, a posição do objeto alvo é comumente fixa em um único ângulo. Isso indica que aquele método foi especializado para tratar de objetos seguindo o mesmo padrão de posicionamento. Tais modelos podem gerar erros que ficam oclusos devido à posição ou forma do objeto.

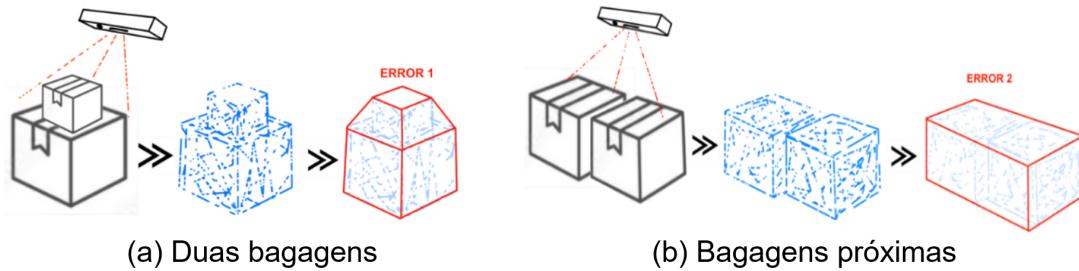


Figura 14 – Possíveis erros ao lidar com mais de uma bagagem

Sobre este item, Ozbay e Cinar (2013) destacam que houve perda de informações devido a não obtenção da *point cloud* em 360°. Isso significa que se o objeto tiver alguma protuberância ou largura maior do lado ocluso, a amostra não coletaria essa informação, gerando erro. Em Ruchay, Dorofeev e Kolpakov (2018), por outro lado, esse problema é amenizado pelo uso de quatro kinects tendo o objeto posicionado ao centro do cenário de captura. Isso indica que existem casos onde é interessante ter duas ou mais perspectivas da *point cloud* para analisar outras faces do objeto.

2.2.4 Pontos em aberto

Mediante a análise qualitativa dos trabalhos selecionados, é possível listar os seguintes problemas pendentes:

- *Reconstrução de múltiplos objetos*: exceto os estudos que utilizaram scanners a laser móveis, nenhum outro aplicou a reconstrução de múltiplos objetos do cotidiano ou bagagens (vide Figura 14b que se baseia no método proposto com sensor de profundidade e ilustra duas situações onde são inseridos múltiplos objetos no *self bag drop*);
 - *Flexibilidade e adaptabilidade*: Esse indicador significa que os trabalhos limitam tanto o cenário de teste quanto a complexidade do objeto. Vários estudos reconstruíram com fidelidade malas no formato cuboide, porém, foi possível identificar que os resultados são altamente influenciados pela posição, forma e quantidade das malas.

Considerando os pontos supracitados, os métodos empregados para identificar pontos alinhados poderiam ser aplicados na obtenção de dimensões de bagagens cuboides. No entanto, continuariam gerando erros nas detecções das dimensões de bagagens com deformações ou formatos não cuboides. Nesse caso, uma solução poderia ser complementar a análise com métodos que obtiveram dimensões de objetos utilizando espelhamento da *point cloud*, conforme destacado na literatura e nos resultados. Já a clusterização pode ser utilizada para detectar as dimensões de múltiplas bagagens. Esse problema surge quando o cliente coloca duas ou mais malas de uma vez no equipamento, por conta da oclusão e

do método poder retornar dados errôneos. Quanto à precisão do sistema, pôde ser notado que existe uma tolerância ao erro de medidas, o que indica que combinar esses métodos com sensores de profundidade pode ser uma boa alternativa para atingir um erro aceitável.

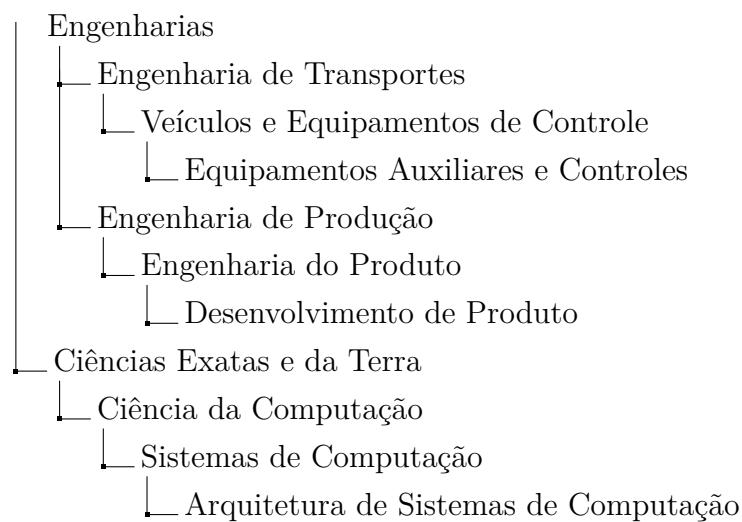
Portanto, com base nos problemas supracitados, é possível afirmar que os principais desafios continuam ligados à capacidade de aplicabilidade em cenários não limitados, a complexidade do objeto, posicionamento e ao custo expressivo do equipamento. Também pode-se destacar que a utilização de mais de um método torna-se interessante para casos de malas com dimensões mais complexas, dados que podem ter grande valia para as companhias aéreas.

3 Materiais e Métodos

No presente capítulo será tratado a classificação e o delineamento da pesquisa. Também serão exploradas cada etapa de desenvolvimento do protótipo do sistema proposto.

Com base nas definições expostas por [Turrioni e Mello \(2012, Cáp. 4\)](#), a presente pesquisa pode ser classificada segundo a natureza, objetivo, abordagem e método. Quanto a *natureza*, esta é uma pesquisa aplicada devido ao caráter prático da solução, que se baseia em explorar o uso de sensores de baixo custo para detecção das dimensões de bagagens. Quanto ao *objetivo*, a pesquisa é exploratória, visto que, busca analisar a capacidade de uso dessa tecnologia para a tarefa citada. Sobre a *abordagem*, é uma pesquisa quantitativa, que busca comparar os resultados obtidos com a tecnologia proposta aos resultados das dimensões reais. Em relação ao *método*, é entendido que a pesquisa desenvolvida tem caráter experimental e de simulação computacional, devido ao objetivo de criação e avaliação de modelos e protótipos.

Ainda, conforme o modelo de classificação disponível pelo conselho Nacional de Desenvolvimento Científico ([CNPQ, 2022](#)), este projeto pode ser classificado em 3 subtópicos. Quanto a engenharias, o subtópico é "Equipamentos Auxiliares e Controles" dado que o produto contribui com o controle no processo de check-in. O segundo é o subtópico de "desenvolvimento de produto" do tópico de engenheira de produção, visto que será construído um protótipo para validar os resultados com chances de dar origem a um produto. Quanto a ciências exatas e da terra é o subtópico de Arquitetura de Sistemas de Computação, uma vez que é desenvolvido um sistema embarcado para automação das partes físicas do projeto. A seguinte árvore ilustra os tópicos citados:



Tendo exposto o delineamento dessa pesquisa, cabe avançar para explicação do desenvolvimento da solução. Sendo assim, visando explorar a efetividade técnica do uso de

equipamentos de baixo custo na detecção de dimensões de bagagens, foi desenvolvido um protótipo. Para tanto, foi adotada uma metodologia de desenvolvimento baseada em fases sequenciais e retroativas com melhoria sucessiva dos modelos e/ou algoritmos mediante testagem e feedbacks. Esse fluxo foi inspirado em métodos tal como Cascata e Scrum, cuja as descrições podem ser encontradas em (BOURQUE; FAIRLEY, 2015). A Figura 15 mostra o modelo geral para obtenção das dimensões das bagagens proposto por essa pesquisa.

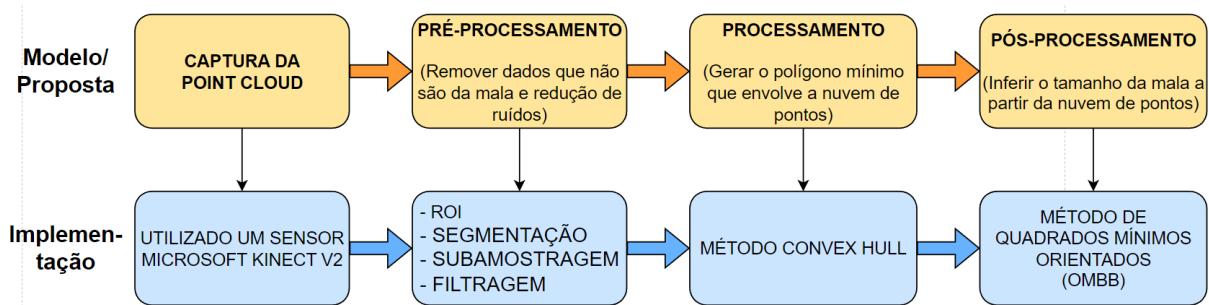


Figura 15 – Fluxograma do modelo proposto para obtenção de dimensões

O fluxo ilustrado na Figura 15 consiste em 4 fases. A primeira etapa é a captura dos dados, para a qual foi construído um dispositivo físico. Na segunda etapa, a *point cloud* é tratada para retirada de ruídos. A terceira etapa consiste em obter os pontos de borda com o convex hull. Na última etapa é obtida as dimensões pelo uso de OMBB. Foram avaliados fatores tais como, custo, tempo de medida, posição do sensor, posição das bagagens e exatidão. Ao longo do texto, são relatadas as dificuldades de implementação e complexidade de incorporação do sensor.

Quanto a estrutura do protótipo, este, deve comportar bagagens de mão e de despacho. Para captura da *point cloud* foi escolhido o sensor de profundidade kinect v2. Isso é devido a seu baixo custo (alinhado com a proposta da pesquisa) e sua alta precisão, dados discutidos na Seção 2.1.

Para o desenvolvimento dos códigos foi escolhido utilizar o MATLAB (MATHWORKS, 2019), devido a existência de drivers para interação com o sensor e bibliotecas para manipulação da *point cloud*. Para a automação das partes estruturais, foi utilizado o Arduino, devido a praticidade e quantidade de módulos disponíveis para automação de dispositivos. As próximas seções detalham os módulos desenvolvidos para a solução.

3.1 Captura da *Point Cloud*

O primeiro passo do modelo proposto consiste em obter a *point cloud*. Para tanto, foi desenvolvido um dispositivo utilizando o sensor de profundidade kinect v2. O equipamento

consegue mover as bagagens através do campo de ação do sensor que captura os pontos da superfície da mala. O sistema realiza esse processo tendo como parâmetros uma região de captura, frequência de amostragem, passo e velocidade da esteira. Para tanto, as dependências que dão suporte ao Kinect v2 no MATLAB utilizadas nessa pesquisa foram as seguintes:

- Image aquisition toolbox: kit para aquisição de dados por meio de alguns dispositivos (câmera, raio-x, Kinect etc) ([MATHWORKS, 2022a](#));
- Image Acquisition Toolbox Support Package for Kinect For Windows Sensor: pacote com drives necessários para comunicar o sistema com o kinect v1 ou v2 ([MATHWORK, 2022](#));

Os recursos disponíveis para o kinect, permitem a obtenção de *point clouds* com cores ou sem cores. A sem cores é chamada de “*Only depth*”, sendo gerada em um menor tempo de processamento que a colorida, esse foi o tipo utilizado nessa pesquisa. Tais dados são reunidos em um Objeto *point cloud*, este, tem as principais propriedades da amostra sendo elas a matriz de pontos (x, y, z) em unidade de metros, matriz de pontos RGB, matriz de intensidade em escala de cinza, número de pontos e limites do plano.

Duas funcionalidades disponíveis para o Kinect e importantes para a solução em questão são a região de interesse (ROI) e a subamostragem. O ROI permite retornar pontos em um limite definido por um vetor contendo as coordenadas de largura, comprimento e altura da região, isso possibilita a delimitação do campo de captura de dados. A subamostragem permite reduzir a densidade de pontos da *point cloud* original, isso contribui com a otimização do tempo de processamento em etapas posteriores ([MATHWORKS, 2015](#); [MATHWORKS, 2017](#)). As seções seguintes detalham a implementação do protótipo.

3.1.1 Modelagem da solução para captura da *point cloud*

Após os testes dos componentes do sistema, foram avaliadas as abordagens para captura e manipulação da *point cloud*. Assim como outros sistemas de visão computacional, na presente pesquisa existem 3 etapas gerais, sendo a captura dos dados, tratamento da *point cloud* e extração dos dados de dimensões. Na primeira etapa foram avaliadas as formas de captura da *point cloud*, sendo elas a captura estática e a móvel.

A captura estática consiste em posicionar o sensor em um ponto fixo e coletar a *point cloud* de um objeto abaixo. Sendo assim, foi escolhida a posição Topo (90°) mostrada na Figura 17. Essa abordagem foi utilizada em trabalhos tal como ([GAO; YANG, 2013](#)) e ([QINGJI; CHUANBO; QIJUN, 2018](#)) porém sem o uso do kinect. Nesse tipo de amostragem, é simulado o caso do passageiro colocar a mala em um ambiente estático (sem

esteira), a bagagem é medida e ele retira a mesma do local. O modelo que ilustra esse processo é mostrado na Figura 16.

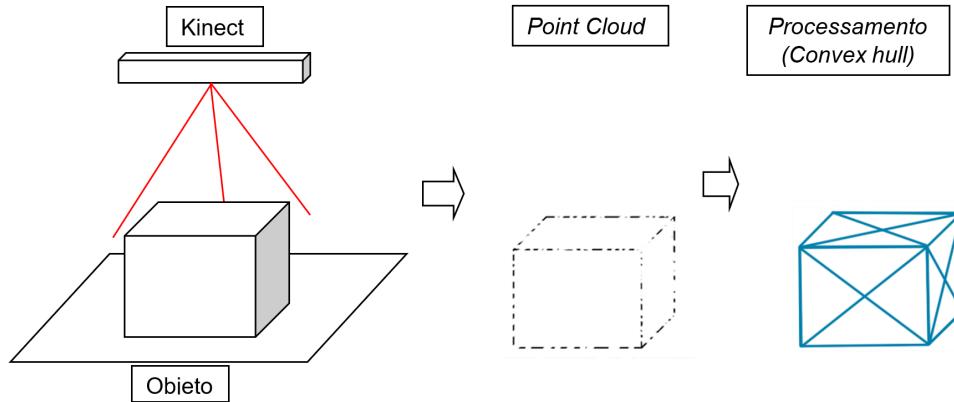


Figura 16 – Amostragem de *point cloud* via sensor kinect

A posição do sensor tem influência nos resultados e no método para obtenção das dimensões. Por exemplo, com apenas um sensor, a visão lateral de 90° que detectá pontos diretos de uma face da mala, poderia ter oclusão de dados, gerando erros caso a mala tenha um comprimento e/ou formato diferente do lado ocluso. Nesse caso, teria que ser adicionada uma fase extra de tratamento para redução dessa oclusão via, por exemplo, espelhamento. A Figura 17 indica quais as posições mais comuns observadas na revisão da literatura.

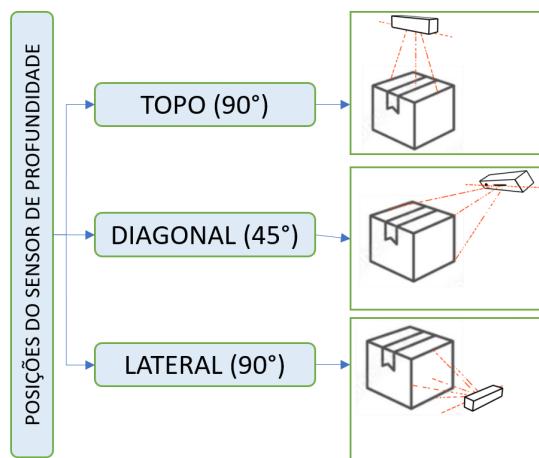


Figura 17 – Posições mais comuns para o sensor

Prosseguindo, a visão Topo (90°) foi selecionada, pois, na presente aplicação, reduz a quantidade de pontos oclusos aumentando o nível de detalhes capturados, como alças e deformações. Dado que é utilizado apenas 1 sensor, as demais posições tem maior chance de ocorrência de oclusão, reduzindo a quantidade de dados coletados das laterais da mala. Para fixação do Kinect e realização do primeiro teste, foi construída uma estrutura mostrada na Figura 18.



Figura 18 – Estrutura de testes com Kinect para amostragem estática

Como pode ser visto na Figura 18, o Kinect foi posicionado na parte superior, a 1 metro da base, apoiado sobre um vidro. As laterais da estrutura estão distanciadas por 0,9 m de largura e 0,8 m de comprimento, totalizando uma área ativa de $0,72m^2$.

Para validação do cenário foi utilizado o Kinect studio com o propósito de visualizar a *point cloud*. A Figura 19, mostra a reconstrução da superfície do cenário em 3D, já com a aplicação do ROI (*region of interest*). Este, é um processo de segmentação onde os pontos fora de uma área definida em termos de largura, comprimento e profundidade são descartados.

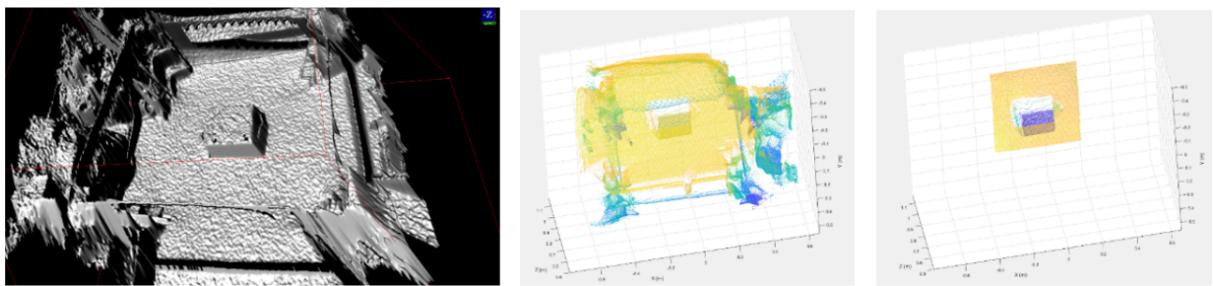


Figura 19 – Cenário de teste com reconstrução visual, *point cloud* com região de interesse (roi) = 40 cm x 40 cm x 50 cm

A captura estática consegue coletar a *point cloud* com riqueza de detalhes. Porém, dado que os tamanhos/quantidade das bagagens são variáveis, não cobre todos os casos, como de bagagens maiores que a área ativa. Uma alternativa seria expandir essa área até o ponto que cobrisse todos os casos permitidos nos aeroportos, mas é um gasto desnecessário de recurso e poderia reduzir a serialização dos testes com várias bagagens. Por isso, essa

abordagem foi utilizada apenas como uma alternativa de aplicação do protótipo.

Diferente do modo estático, a captura móvel não tenta prever o tamanho das bagagens. Nesse caso, é definido um *slice* que corresponde ao ROI de captura, passo de amostragem e uma frequência de amostragem. Essa abordagem consiste em se posicionar o sensor em um ponto fixo e mover o objeto pela região de ação do mesmo.

Dado o comportamento da captura móvel, foi desenvolvido um protótipo. Para tanto, foi acrescentado ao sistema uma esteira, capaz de mover uma bagagem através da região de amostragem do sensor. A Figura 20 ilustra a ideia do protótipo, composta pelos passos a seguir:

1. O sensor permanece capturando dados e verificando a presença de um objeto dentro da região alvo;
2. A central de controle representada pelo Arduino move o objeto acionando um motor que gira uma esteira;
3. O objeto atravessa o campo de visão do sensor;
4. A *point cloud* é capturada em fatias (*slices*), que são unidas em um só conjunto.

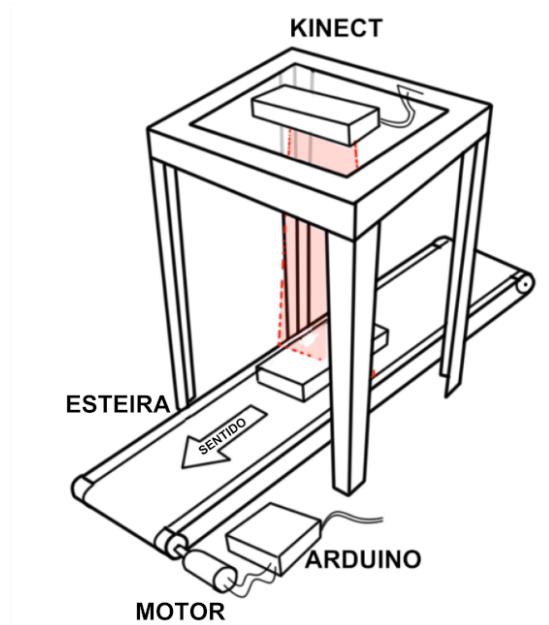


Figura 20 – Modelo do protótipo físico para obtenção de dimensões de bagagens

Como o objetivo final é trabalhar com o sistema em aeroportos, onde o cenário das bagagens é dinâmico, esta foi a abordagem selecionada para a construção do protótipo. Em próximas seções esse método será detalhado.

3.1.2 Desenvolvimento do hardware e algoritmo de captura de dados

Esta subseção trata do desenvolvimento do protótipo físico. Este, foi baseado no modelo mostrado na Figura 20. Serão expostos os pontos principais quanto as medidas, central de controle, montagem e algorítimos utilizados.

Quanto as medidas, foi constatado via teste que o alcance mínimo do sensor é aproximadamente 0,5 m com um erro de $\pm 0,06$ em média. Esse erro pode ser originário da reflexão do sensor na superfície do objeto, ou mesmo de imprecisões no dispositivo. Isso significa que essa é a distância mínima para coleta de dimensões, tendo influência no produto final desta pesquisa, já que as partes físicas estarão limitadas ao campo de ação do sensor. Por tanto, a altura mínima adequada para o sensor, na posição topo 90°, é 1 m.

Dado que existem limites para que a esteira comporte as bagagens, foi seguido a medida máxima para bagagens de despacho, o que permite inserir também bagagens de mão, essas dimensões são informadas na Seção 2.1.1. Com isso, as laterais da estrutura têm 0,7m de largura e 1,10m de comprimento (área total de 0,77m) com o sensor posicionado, por padrão, a 1m de altura. Também foi considerada uma tolerância de 20cm a mais para cada medida.

Com isso, foi construída uma estrutura de fixação para o Kinect que pode ser acoplada na esteira, a Figura 24 mostra o resultado. Como citado, a posição selecionada para o sensor foi a topo 90° que reduz o número de pontos oclusos, aumentando o nível de detalhes como alças, etiquetas, deformações, objetos presos a mala e rodas.

A construção da esteira consistiu em duas partes, sendo a primeira o desenvolvimento do algoritmo a ser gravado no Arduino para central de controle e a segunda, a construção do hardware da esteira. A modelagem e simulação do circuito foram feitas no Proteus (PROTEUS, 2022), um sistema para simulação de circuitos. A Figura 21, mostra o modelo gerado e os componentes utilizados. Mais detalhes da implementação estão no Apêndice A.

Na Figura 21 é possível visualizar a presença dos módulos do circuito. O Arduino é o microcontrolador e a Ponte H permite o controle isolado do motor, possibilitando inversão de sentido e controle da velocidade por PWM (pulso com modulação - *pulse width modulation*). Também foi implementado um controlador feedback em malha fechada para ajustar o RPM (Rotações por minuto) do motor. O Motor DC movimenta o tapete da esteira, sendo este de 12 V e pelo menos 4 A. No código, o PWM é controlado por um valor entre 0 e 255. A equivalência é de 1 para 0,00211 m/s. As opções de controle da esteira podem ser acessadas via porta serial, interface mostrada no Apêndice B ou por botões, sendo elas as seguintes:

- Push button 1: controle do sentido de rotação, horário ou anti-horário;

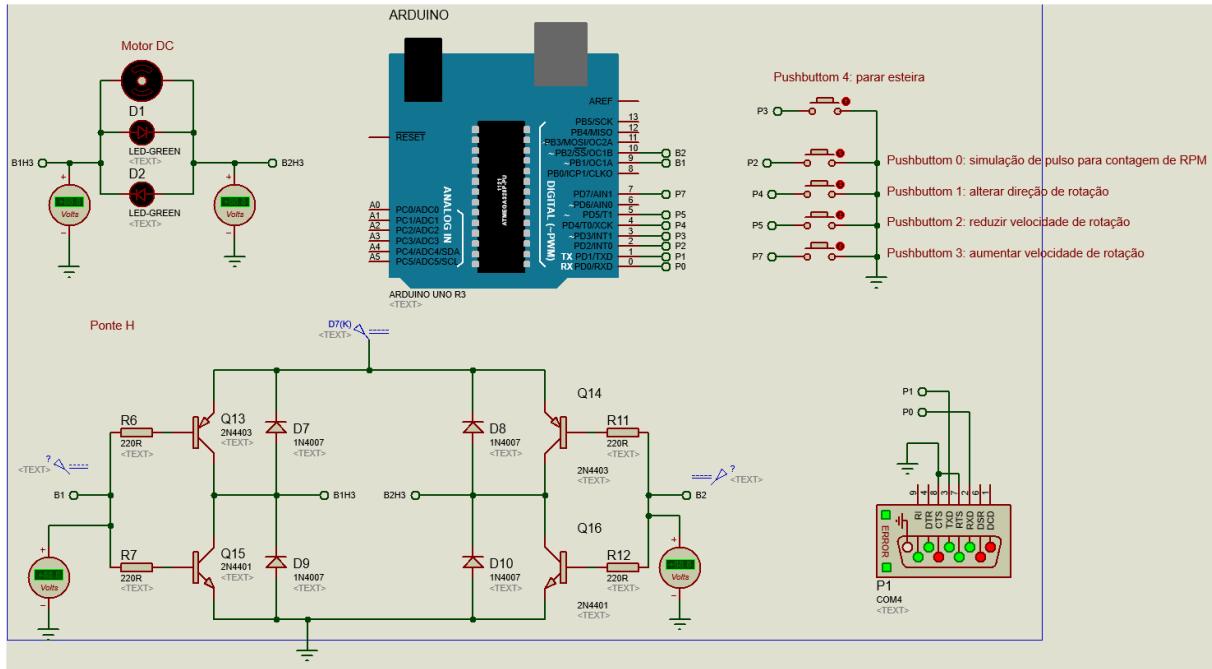


Figura 21 – Simulação do Circuito da Central de controle da esteira

- Push button 2: aumentar a velocidade de rotação. Permite até cinco velocidades, sendo elas (sem carga):
 - Velocidade 1: $0m/s$;
 - Velocidade 2: $0,0895m/s$;
 - Velocidade 3: $0,205m/s$; (Padrão)
 - Velocidade 4: $0,352m/s$;
 - Velocidade 5: $0,538m/s$.
- Push button 3: reduzir velocidade da esteira, até $0m/s$;
- Push button 4: botão de emergência que para a esteira por meio de uma interrupção.

Partindo para etapa de montagem do circuito, após testes fora da esteira, este foi colocado em uma caixa para proteção. A Figura 22 mostra o sistema fora e dentro da caixa:

Para um controle mais adequado da esteira, foi construído um painel. Este, é constituído de 4 pushbuttons, madeira e suportes plásticos para que os botões fiquem maiores e, consequentemente, mais fáceis de acionar, a Figura 23 mostra o painel.

Partindo para a construção do protótipo, nessa etapa, foi reutilizada a estrutura de uma esteira de ginástica. Além de reparos e limpeza, também foram feitas algumas adaptações para atendimento dos requisitos do protótipo, as principais foram:

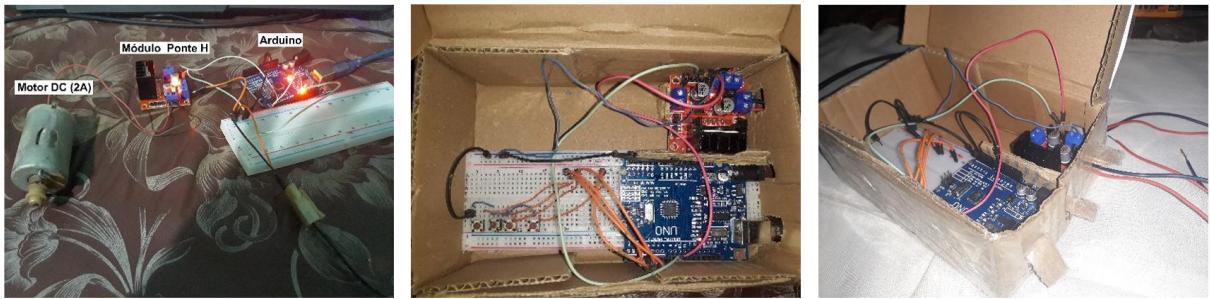


Figura 22 – Central de controle da esteira



Figura 23 – Painel de controle do protótipo

- Fixação do motor do protótipo e correia especial. A correia e a engrenagem do motor realizam uma redução na polia do rolete principal, isso gera mais torque na esteira. Também foi criado um esticador de correia no processo;
- Troca do tapete por um macio e compatível com a força do motor;
- Manutenção dos roletes que estavam travados e ajustes da tensão do tapete.

Dado que a estrutura é resistente, ela atende aos requisitos dos testes. A estrutura de fixação do kinect foi presa na esteira, em um local neutro (sem necessidade de ação do sensor). A Figura 24 mostra o protótipo da esteira.

Pela análise da Figura 24, é possível notar que a base do sensor está a 1 m de altura. O braço de fixação é móvel em três direções (cima, baixa e frente), isso foi utilizado para ajustes e testes quanto a altura do kinect, permitindo a configuração para até 1,5 m. A Figura 25 mostra a visão do kinect do cenário de teste de forma estática e a Figura 26 a *point cloud* extraída com a amostragem móvel de uma mala.

A captura móvel é realizada mediante alguns parâmetros, sendo eles um *slice* (roi da captura), que define a região da *point cloud* a ser coletada, passo de amostragem e frequência de amostragem. A partir disso, o sensor é posicionado na estrutura de fixação e a mala é movida pela região de ação do mesmo. Sendo assim, são realizadas N capturadas de *point clouds*, os chamados *slices*, para serem unidos formando uma *point cloud* completa

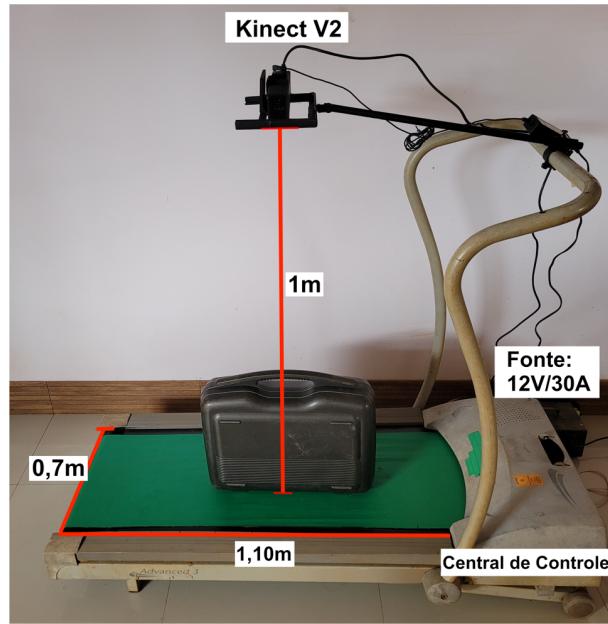


Figura 24 – Protótipo do sistema com esteira e estrutura para posicionar o sensor

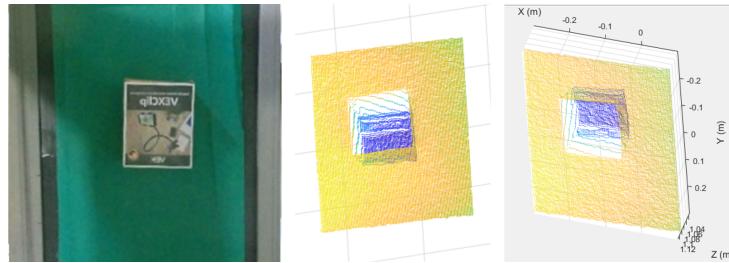


Figura 25 – *Point cloud* do ambiente da esteira

da bagagem. Com isso, a diferença desse método para o estático é a necessidade de realizar um tratamento mais extenso, consistindo em concatenar todas as amostras para formar a *point cloud* final. O Algoritmo 1 mostra a lógica seguida para aplicação dessa abordagem. A implementação desse algoritmo pode ser acessada no Apêndice A.

Pela análise do algoritmo é possível separar o processo de captura nos seguintes passos:

1. Definir parâmetros de entrada:

- Passo de amostragem: depende da velocidade com que o objeto irá passar pelo sensor. Foi utilizado 5 cm e a opção 3 de velocidade (0,205 m/s);
- Roi: corresponde ao *slice* de amostra, foi utilizado 5 cm de comprimento por 50 cm de largura;

2. Realizar amostragem da point cloud:

- Para cada amostra, concatenar a mesma em uma matriz de pontos resultante;

Algoritmo 1: Captura de *point cloud* móvel

Entrada: O sensor Kinect K , o passo de amostragem a em metros, a altura do sensor h , a região de interesse r de captura e a tolerância t de amostras para término

Saída : Nuvem de pontos (*point cloud*) P

$P \leftarrow \{\}$

$f \leftarrow$ calcule a frequência do sensor com base na amostragem a

inicie o sensor K com a frequência f

$numpassos \leftarrow 0$

enquanto a tolerância t de amostras sem objetos não for atingida **faça**

$p \leftarrow$ leia a point cloud do sensor K

$p_r \leftarrow$ retorne somente os pontos na região r de p

$p_m \leftarrow$ mova os pontos p_r na direção do eixo y em $(numpassos * a)$

$P \leftarrow P \cup p_m$ ▷ concatena os pontos p_m a *point cloud* P

$numpassos \leftarrow numpassos + 1$

fim

retorna P

3. Retorna a Point Cloud resultante.

Como pode ser percebido na Figura 26, foi possível utilizar o método móvel para amostrar os pontos do objeto.

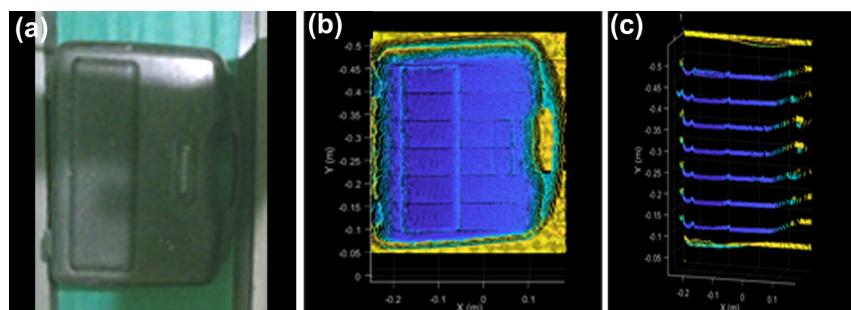


Figura 26 – *Point cloud* da mala 1 e tamanho do slice por captura. (b) slice1 = 5 cm x 50 cm x 50 cm. (c) slice2 = 1 cm x 50 cm x 50 cm

Nota-se que existem duas medidas para *slices* (ROI). A Figura 26b tem um *slice* de 5 cm x 50 cm x 50 cm, apresentando mais detalhes da bagagem, consequentemente, produzindo resultados mais precisos. Já a Figura 26c tem um *slice* de 1 cm x 50 cm x 50 cm, coletando menos detalhes, porém reduzindo tempo de processamento e complicações como quando os pontos se sobrepõem entre dois passos. Contudo, para os testes foi utilizado o slice1 da 26b, que retorna resultados mais precisos.

3.2 Processamento da *point cloud*

Na presente Seção será exposto o fluxo de tratamento da *point cloud* desenvolvido para o protótipo, assim como a explicação de cada etapa adotada. Nesse caso, uma observação relevante é que o fluxo de tratamento inicial com Roi e segmentação é efetivo para trabalhar com a *point cloud* em cenários menos exigentes. Isso é devido à precisão do Kinect, que não apresenta muitos ruídos (*outliers*). No entanto, pode ocorrer pequenos desvios dos pontos por conta da reflexão natural do infravermelho na superfície da bagagem.

Tendo em vista essa questão, mostrou-se interessante realizar uma filtragem para normalizar a posição dos pontos e retirar ruídos. Isso pode aumentar a exatidão das medidas. Outra vantagem é que, dada uma etapa de filtragem, pode ser desenvolvido um processo preparado para retirar outlier exagerados, como, por exemplo, pontos totalmente fora da bagagem. Sendo assim, a Figura 27 ilustra o fluxo completo de tratamento da *point cloud* desenvolvido na presente pesquisa. É importante destacar que o convex hull também foi ilustrado nesse fluxo dado que ele pertence à etapa de processamento.

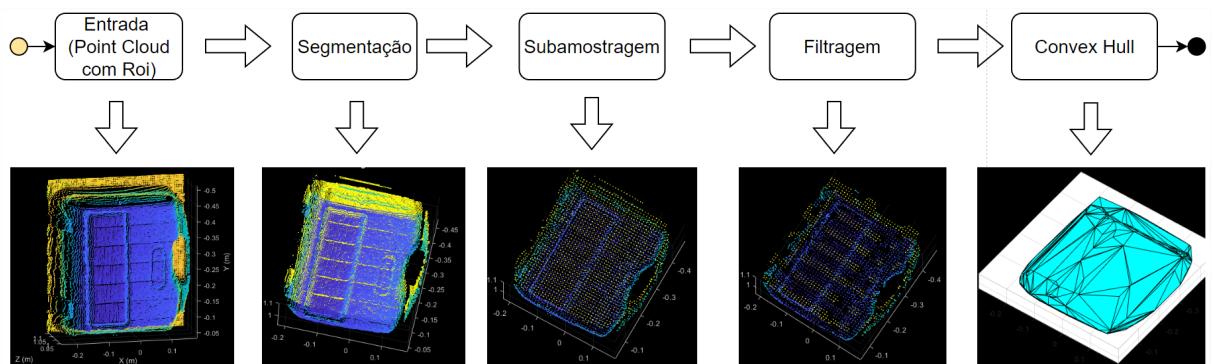


Figura 27 – Fluxo de tratamento da *point cloud* de bagagens para extração de dimensões slice = 5 cm x 50 cm x 50 cm

O fluxo de tratamento consiste dos seguintes passos:

1. Entrada: Obter a *point cloud*;
2. Segmentação: são filtrados os pontos de modo a descartar os que fazem parte da base da esteira;
3. Subamostragem: consiste em filtrar a *point cloud* reduzindo a densidade de pontos;
4. Filtragem: é aplicado filtro de média na *point cloud* de modo a normalizar a posição dos pontos;
5. Convex hull: É utilizado para retornar os pontos de extremidade da mala, na Figura 27 é mostrado por triangulação em azul para melhor visualização.

É interessante mencionar que esse tratamento adiciona uma tolerância ao sistema, permitindo que pequenos objetos próximos à bagagem sejam cortados da medida. Sendo assim, é interessante discutir sobre as principais etapas do fluxo que são a segmentação, subamostragem, filtragem e convex hull.

O processo de segmentação consiste em selecionar, da *point cloud* de entrada, apenas os pontos que pertençam a um conjunto delimitado por uma constante de corte. Considerando a posição Top 90°, tem-se que a distância do sensor a base é uma constante conhecida. A partir disso é realizado um rastreio na *point cloud* identificando e recuperando apenas os pontos que estão 5 cm acima do fundo. Ainda nesse processo, para cada ponto da mala, são adicionados pontos na altura da base em paralelo. Isso é feito para gerar o formato final do objeto e garantir um melhor resultado para o convex hull. Ou seja, sendo P_i um ponto do conjunto de corte, é feita uma concatenação gerando uma *point cloud* P_r .

No presente modelo, a segmentação é um passo importante, dado que retira os pontos da base da esteira restando apenas os pontos da mala. Se a posição do sensor for alterada para, por exemplo, diagonal 45°, essa fase é o principal elemento do modelo que deve ser adaptado para possibilitar a aplicação dos outros passos de tratamento e a obtenção das dimensões.

Já a subamostragem consiste em, dado um valor inteiro de passo, iterar sobre a *point cloud* coletando os pontos que condizem com o mesmo. Para garantir um resultado uniforme que represente a mala original, é estabelecido a porcentagem mínima de pontos a serem retornados ao final da subamostragem. Esse processamento tem o principal objetivo de reduzir a quantidade de pontos a serem processados na medida. Ocasionalmente, podem ser retirados alguns *outliers* nessa lógica.

A etapa de filtragem é a mais extensa, e consiste da aplicação de um filtro de distância média que descarta pontos fora dos limites da mala. Esse filtro é uma variação do conceito do DbScan, descrito na Seção 2.1.6.2. No caso, é considerado um valor de distância de descarte (*threshold*) e o número de vizinhos (N) que serão englobados para cada ponto P_i . Por padrão, esses números foram definidos como 1 e 3 respectivamente.

A partir desses dados é realizado um rastreio na *point cloud*. Um ponto é considerado outlier quando o desvio padrão da distância média entre seus N vizinhos mais próximos é maior que o threshold especificado. Tomando como referência a Figura 28, é indicado alguns outliers que são descartados da *point cloud*. Também são ilustrados os dados de distância e número de vizinhos definido para o filtro.

É importante destacar que, os pontos descartados não correspondem a pontos de alças, rodas ou etiquetas. O intuito dessa etapa é apenas uniformizar a *point cloud*, para melhorar a exatidão do modelo. Possíveis origens dos outliers ilustrados são os já mencionados reflexos do sensor nas superfícies, que, por vezes, não são retirados em etapas

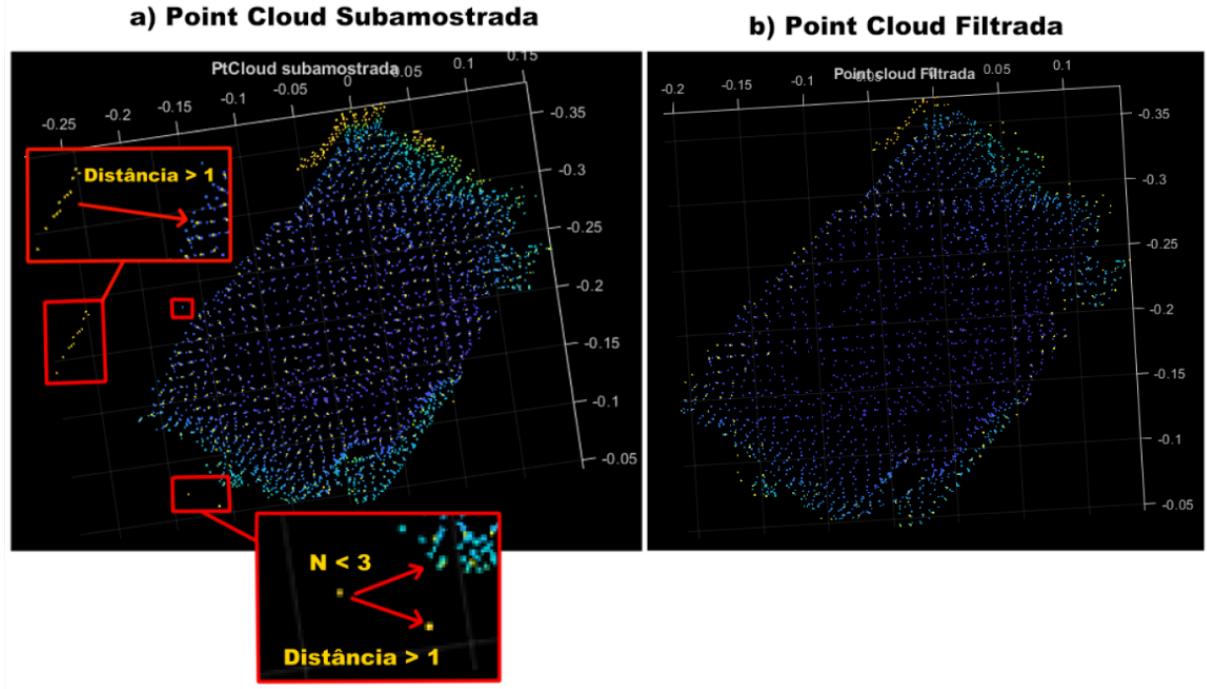


Figura 28 – Filtragem de *point cloud* de uma mala $N = 3$, threshold = 1

anteriores a filtragem.

Outra vantagem da filtragem é que pequenos objetos (ex. moeda, chave, batom, caneta) que possam ter caído na esteira e que não estejam anexados a bagagem, são cortados e não influenciam o resultado.

No final de todo o processo citado, é aplicado o convex hull para coletar os pontos de extremidades da *point cloud* tratada. Esses pontos representam o menor polígono que reveste toda a superfície da bagagem. A partir disso já é possível obter dados quanto ao volume real, isso é, o volume que corresponde ao formato discretizado da mala.

A etapa seguinte é o pós-processamento, que utiliza os pontos de hull para medir os valores de largura, altura e profundidade. A partir desses dados pode ser calculado o volume de armazenagem da bagagem na aeronave, que é em formato de paralelepípedo. Sendo assim, existem dois dados que podem ser utilizados para aprimorar o processo de check-in e despacho.

3.3 Pós-processamento

Recapitulando, o desenvolvimento do sistema foi dividido em captura, tratamento de dados e extração de dimensões. Nessa Seção serão explorados os métodos criados para extração das dimensões da *point cloud*. Segundo os dados da revisão sistemática, os algoritmos mais utilizados para esse fim são o convex hull e quadrados mínimos (MBB)

(GUFFANTI et al., 2020; GAO et al., 2018; CHEN et al., 2013).

Nessa pesquisa foi utilizado o convex hull para extração do volume mais próximo ao formato da bagagem e obtenção dos pontos de extremidade. Já o OMBB foi utilizado para retornar as dimensões aproximando o formato a um paralelepípedo, fornecendo uma medida bem próxima do que é feito na prática dos aeroportos. Esse método também garante que, caso a mala esteja em outra posição, por exemplo, diagonal, seja possível calcular os dados baseada na orientação da *point cloud*.

A abordagem adotada é inspirada no fluxograma ilustrado na Figura 12, dividido em 2 fases. Na primeira é aplicado o AABB, em sequência o resultado é manipulado para obter o OMBB, os seguintes detalhes podem ser pontuados:

- Fase 1: são retornados os dados dos limites x, y e z da *point cloud* alinhado com os eixos. É importante salientar que a *point cloud* de entrada já corresponde aos pontos do convex hull. Esse resultado consiste em um retângulo que tangêncio os limites máximo e mínimos da mesma;
- Fase 2: o resultado do passo 1 é rotacionado no sentido horário pelo uso de uma matriz de racionamento. A cada passo de rotação os pontos são movidos de modo a ajustar a área do retângulo ao formato da *point cloud*, armazenando sempre o retângulo de menor área. Esse processo é repetido até todos os pontos de hull terem colidido ao menos uma vez com alguma extremidade das linhas do retângulo, então é retornado o retângulo de menor área que engloba os pontos, esse, corresponde ao OMBB.

A partir dos pontos de vértice do retângulo mencionado, é possível calcular a Altura, largura, profundida e volume do objeto de forma simplificada. Para tanto, é computado o módulo dos vetores entre os pontos de vértice das laterais desse retângulo, correlacionando esses dados com as informações de dimensões citadas.

Essa lógica, consequentemente, aproxima qualquer objeto a um corpo em formato de caixa. Como mencionado, para obtenção do volume do objeto de maneira mais fiel ao formato da *point cloud*, o método convex hull foi utilizado.

4 Resultados e Discussões

A presente seção tem por objetivo expor e avaliar os resultados obtidos a partir dos testes com o protótipo. Serão discutidos dados referentes a exatidão, tempo de medida e capacidade do sistema, sendo indicados os parâmetros utilizados. Ao final serão feitas considerações quanto aos dados obtidos.

4.1 Resultados dos testes do protótipo

Para avaliar o modelo proposto, foram testadas posições diferentes do sensor e das bagagens, sendo observados os resultados com malas deitadas, de lado, em pé e na diagonal, separadamente. Cada mala na determinada posição foi medida 10 vezes, reunindo nos resultados as médias desses valores. Inclusive, a questão das posições é citada como ponto em aberto nos trabalhos da revisão. Os testes foram realizados utilizando o Roi de 5 cm, capturando dados a um passo de 5 cm.

4.1.1 Testes com sensor em diferentes posições

Para validar qual o ponto de melhor exatidão do sensor no protótipo, foram realizados testes em diferentes posições. Desse modo, foram selecionadas 3 alturas para testar com o sensor, sendo elas 1 m, 1,25 m e 1,50 m. A discussão quanto a altura e posição do sensor também foi observada como ponto em aberto nos trabalhos da Seção 2.2.

Cada altura foi testada com uma mala deitada e em pé, ambas na horizontal. Para cada altura foram retiradas 10 medidas e calculadas as médias dos valores. As malas são mostradas nos testes de número 1 das Figuras 29 e 30, já a Tabela 3 mostra o erro absoluto médio (MAE) retornado para as medidas. Os campos da tabela são Largura (L), Altura (A), Profundidade (P) e o tempo de medida (TM).

N	Altura do Sensor (m)	L (cm)	A (cm)	P (cm)	MAE	TM (s)
1	1	1,305	0,42	0,77	0,83	2,7
2	1,25	2,715	3,34	0,195	2,08	2,05
3	1,50	7,035	0,895	2,735	3,56	1,44

Tabela 3 – exatidão do protótipo para alturas diferentes do sensor

Pela análise dos dados da Tabela 3, é possível perceber algumas diferenças importantes. Primeiro o menor MAE foi para a altura de 1 m (0,83 cm) indicando que essa

posição retorna um resultado geral melhor, sendo que também é a altura mínima para o uso com malas de mão e de porão. Ainda, os erros de L incrementaram a cada teste chegando a 7,035 cm, já as dimensões A e P, tiveram os piores resultados nas alturas 1,25 m e 1,50 m. Sendo assim, os dados indicam que existe um erro de acuraria ligado a distância do sensor, sugerindo que, para o presente protótipo, uma proximidade de 1 m do sensor com a base da esteira gera menores erros.

Outra informação observada é o decréscimo no tempo de medida. O tempo no teste 1 foi de 2,7 s até o mínimo de 1,44 s no teste 3 com altura de 1,50 m que teve o pior MAE. Por tanto, a exatidão está inversamente relacionada à altura que está diretamente relacionada à velocidade. Isso indica que é possível ajustar a posição do sensor para cenários onde a tolerância de erro é maior, obtendo assim, resultados mais rápidos.

Quanto ao modelo final da presente pesquisa, é preferível ter a melhor exatidão possível para evitar transtornos e perdas financeiras. Por tanto, a altura selecionada como padrão para o protótipo foi de 1 m, visto que, nesse escopo, existe maior tolerância para o tempo do que para a exatidão.

4.1.2 Testes com malas em posição deitada

Os primeiros testes realizados foram com as malas em posição deitada. A Figura 29 mostra as malas utilizadas nos testes e a Tabela 4 os resultados obtidos. Para cada bagagem foram coletadas 10 medidas e a partir disso foi calculada a média entre os valores. Os campos marcados com (R) são os valores reais e os campos marcados com (K) os valores retornados pelo sistema. A coluna N representa o código identificador da bagagem em questão. Os dados estão em termos de largura (L), altura (A), profundidade (P) e volume (V).

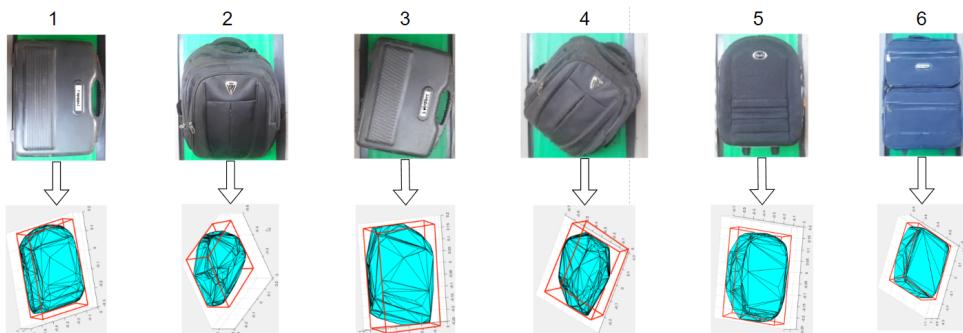


Figura 29 – Testes Com malas deitadas (convex hull e OMBB)

A partir da análise dos resultados da Tabela 4, é possível observar que, para a mala 1, posicionada horizontalmente, obteve-se um MAE de 0,25 cm. Já a mochila 2 obteve MAE de 1,13 cm. Tais erros podem ser gerados, para além da amostragem e posição da mala, por pontos levemente deslocados devido à reflexão do sensor ao colidir com a

N	L (R) cm	A (R) cm	P (R) cm	V(R) m3	L(K)cm	A (K) cm	P(K) cm	V(K) m3	MAE
1	42,50	50	17,80	0,037	42,58	50,24	17,35	0,0371	0,25
2	42,10	55,23	18,50	0,043	42,60	56,98	19,65	0,0476	1,13
3	42,50	50	17,80	0,037	42,50	48,81	17,25	0,036	0,58
4	42,10	55,23	18,50	0,043	43,38	48,79	18,54	0,040	2,58
5	37,30	51,80	20,10	0,038	38,97	52,88	19,76	0,040	1,03
6	41,00	58,01	22,00	0,052	44,71	59,14	21,65	0,057	1,73
MAE médio				1,21		1,97	0,48	0,003	1,22

Tabela 4 – Resultado da exatidão do protótipo, malas deitadas

superfície da mala. Outro fator que corrobora com os erros é o material macio da mochila 2, materiais macios, sempre que manuseados, podem se deformar e alterar as dimensões. Como durante os testes a 2 foi reposicionada, os resultados se alterarão em cada amostra.

Os testes 3 e 4 foram realizados com as bagagens rotacionadas na diagonal. Os erros retornados foram de 0,58 cm e 2,58 cm, respectivamente. Em comparação com os resultados obtidos em 1 e 2, houve um aumento, isso se deve ao tratamento exclusivo que o algoritmo tem que realizar ao considerar que a nuvem de pontos é rotacionada. Outro fator que afeta os resultados são os slices de amostra que, dado que a mala está rotacionada, podem gerar leves erros de deslocamento de pontos, como, por exemplo, serrilhados.

Os testes 5 e 6 retornaram MAE de 1,03 cm e 1,73 cm, respectivamente. O maior erro absoluto dessas medidas ocorreu para os valores de altura, 1,12 cm. Ao comparar os resultados de 5 e 6 com 1, é possível notar indícios de que o erro é cumulativo. Isso pode estar relacionado à etapa de amostragem e o passo definido ou à necessidade de tratamentos extras da *point cloud*, como filtragem.

4.1.3 Testes com malas em posição de pé

A segunda etapa de testes consistiu em coletar as dimensões das bagagens em posição de pé. Os resultados são mostrados na Tabela 5. A Figura 30 mostra as malas utilizadas e a visualização dos dados coletados.

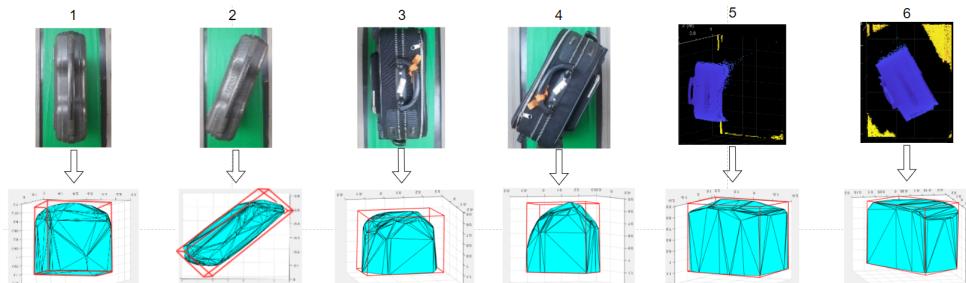


Figura 30 – Testes com malas em pé (point cloud, convex hull e OMBC)

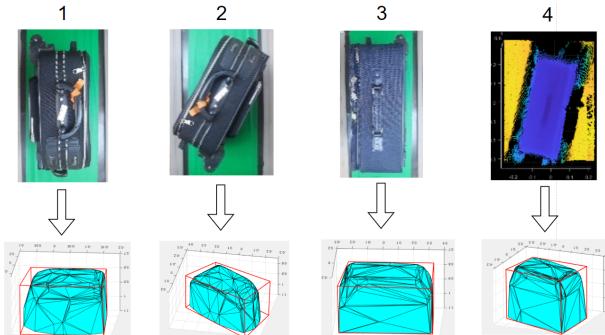
N	L (R) cm	A (R) cm	P (R) cm	V(R) m3	L(K)cm	A(K) cm	P(K) cm	V(K) m3	MAE
1	42,50	50	17,80	0,037	39,97	49,40	18,89	0,0372	1,41
2	42,50	50	17,80	0,037	39,95	52,89	19,09	0,0403	2,24
3	37,30	51,80	20,10	0,038	36,45	54,81	23,58	0,047	2,45
4	37,30	51,80	20,10	0,038	37,40	56,21	22,95	0,048	2,46
5	41,00	58,01	22,00	0,052	38,82	59,66	25,33	0,058	2,39
6	41,00	58,01	22,00	0,052	39,07	60,00	24,21	0,056	2,04
MAE médio				1,69	2,43	2,4	0,005	2,16	

Tabela 5 – Resultado da exatidão do protótipo, malas de pé

O MAE total obtido para a mala de pé foi maior que o MAE das bagagens em posição deitada. A maior diferença foi o erro retornado na profundidade, sendo 1,92 cm a mais que o anterior. Isso é um indício de que a altura da bagagem pode influenciar na medida, provavelmente pelo topo estar mais próximo do kinect e existir diferenças na reflexão do IR.

4.1.4 Testes com malas em posição de lado

A terceira etapa de testes consistiu em coletar as dimensões das bagagens em posição de lado. Os resultados são mostrados na Tabela 6. A Figura 31 mostra as malas utilizadas e a visualização dos dados coletados. Nesse caso, a mala 1 e a mochila, não foram inclusas por não terem apoios de fábrica, para permanecerem nessa posição.

Figura 31 – Testes com malas de lado (*point cloud*, convex hull e OMBB)

N	L (R) cm	A (R) cm	P (R) cm	V(R) m3	L(K)cm	A(K) cm	P(K) cm	V(K) m3	MAE
1	37,30	51,80	20,10	0,038	35,36	50,34	24,97	0,044	2,76
2	37,30	51,80	20,10	0,038	34,96	61,80	25,09	0,054	5,78
3	41,00	58,01	22,00	0,052	39,22	62,79	30,24	0,074	4,93
4	41,00	58,01	22,00	0,052	39,10	68,17	31,96	0,085	7,34
MAE médio				1,99	6,6	7,01	0,012	5,20	

Tabela 6 – Resultado da exatidão do protótipo, malas de lado

4.2 Discussão quanto aos resultados gerais

A Tabela 7 resume os resultados dos erros retornados em centímetros. Os dados estão divididos por posição da bagagem, sendo o campo MAE total a média geral dos erros naquela posição.

Posição	Largura (cm)	Altura (cm)	Profundidade (cm)	Volume (m^3)	MAE total
Deitada	1,21	1,97	0,48	0,003	1,22
Em pé	1,69	2,43	2,4	0,005	2,16
De lado	1,99	6,6	7,01	0,012	5,20
Média	1,63	3,7	3,3	0,007	2,86

Tabela 7 – Comparação dos MAEs em diferentes posições

Por meio da análise dos erros, é possível perceber que os melhores resultados são das medidas com malas deitadas. Em contraste, o pior resultado foi para a posição em pé. Nesse caso, dois pontos de atenção são os erros de comprimento e profundidade. Enquanto os erros de largura permaneceram uniformes, os outros aumentaram significativamente de uma posição para outra. Isso indica uma instabilidade quanto a essas medidas.

Em relação ao comprimento, essa instabilidade pode ser advinda da amostragem. Isso se deve a quedas na taxa de quadros de captura do sensor kinect. Outro fator que contribui são alterações na velocidade da esteira no momento da medida, influenciada por aquecimentos, atritos e o peso das malas. Uma forma de amenizar esse problema é aumentar o torque do motor e melhorar o controle de velocidade.

Quanto ao tempo gasto por medição, o sistema utiliza uma média de 0,14 s/cm. Isso significa que, por exemplo, dada uma mala com 80 cm de comprimento (a maior medida segundo a ANAC para bagagem de despacho), o sistema gastaria 11,8 s. Como o tempo de medição influencia diretamente no check-in, é interessante fazer melhorias no sistema, como, por exemplo, reduzir o tempo de máquina do algoritmo e aumentar a velocidade da esteira.

Pelo levantamento dos resultados de todos os testes, o erro absoluto médio foi de 1,63 cm para largura, 3,7 cm para comprimento e 3,3 cm para profundidade, totalizando um erro absoluto médio de 2,86 cm. Sendo assim, o sistema tem potencial para ser utilizado na prática, especialmente se as bagagens forem dispostas com o mínimo de padronização.

4.3 Simulação de operação do modelo proposto

Na presente seção, será discutido um cenário de testes de operação do modelo de medida de bagagens desenvolvido nessa pesquisa. Tal cenário consiste em uma simulação de processo de check-in utilizando dados reais, focado apenas no *tempo de medida de*

bagagens. Os cenários exploram sempre os piores casos, ou seja, são considerados os valores máximos para qualquer processo ou medida. Para fins de comparação, foram buscados dados com resultados ótimos indicados pela IATA (2022) e outras pesquisas. Considerando que cada companhia aérea pode estabelecer os limites de peso e bagagem de acordo com suas próprias normas, foram levados em conta os parâmetros técnicos do modelo da aeronave.

Primeiramente, é fundamental destacar dois aspectos relacionados à operação de *self bag drop* nas esteiras de atendimento: o posicionamento e a eficiência. Em relação ao posicionamento, optou-se pela abordagem *two-step* conforme descrita na Seção 2.1.4.1, uma vez que o foco principal é o tempo de medição. No que tange à eficiência, não foi identificada, durante a revisão, uma norma universal que estabeleça um tempo máximo. Isso pode variar significativamente devido às diferenças de tecnologia, capacidade e usabilidade. Contudo, é importante mencionar discussões, como a realizada por FTE (2008), que sugerem que, independentemente do posicionamento (seja "one-step" ou "two-step"), o processo de medição de bagagem pelo *self bag drop* deve ser concluído em, no máximo, 30s, sendo o tempo ideal 15s.

Dado as definições expostas, foi selecionada a aeronave A320 para o cenário, a mesma é ilustrada na Figura 32. A Tabela 8 reúne as principais definições da aeronave, tais informações foram retiradas do modelo técnico disponibilizado em (CARGO, 2023). O A320 comporta até 150 passageiros, com capacidade de 25kg de bagagens de mão por pessoa com bagageiro para 104 bagagens. O porão é dividido em compartimento da frente, que suporta 3 contêineres somando até 3402kg e traz, que suporta 4 contêineres somando até 4536kg. O BULK, que é um compartimento para cargas em tamanho e forma fora do padrão, suporta até 1497kg (CARGO, 2023; AIRFRANCE, 2019).

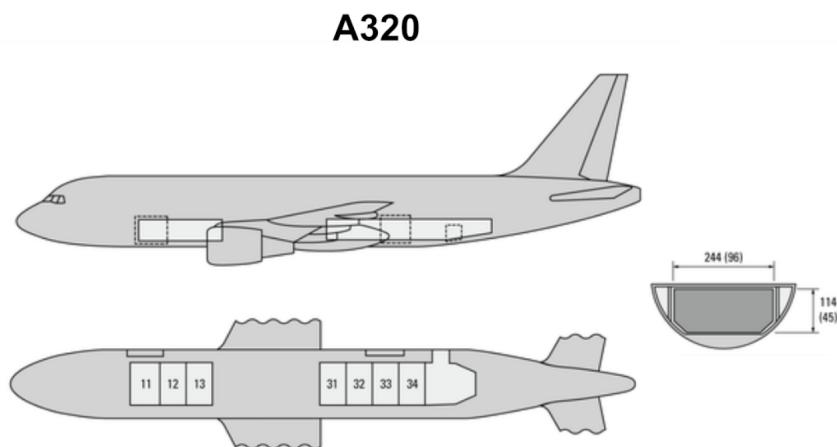


Figura 32 – Modelo técnico A320. Adaptado de (CARGO, 2023)

Para compor o cenário, foram consideradas as recomendações quanto a bagagens descritas na Seção 2.1.1. Referente a quantidade, o estudo de Appelt et al. (2007) realizado

Atributo	Valor	Total
Quantidade de passageiros total	150	
Capacidade de bagagens de mão	Até 104 bagagens Até 25kg por passageiro	3 containers
	Frente (FWD)	3402kg Aproximadamente 148 malas
	Trás (AFT)	4 containers 4536kg Aproximadamente 197 malas
Área do porão	Bulk	1497kg

Tabela 8 – Definições técnicas da aeronave A320 ([CARGO, 2023](#))

no aeroporto internacional de Buffalo Niagara, indicou que em média se tem 1,61 bagagens por passageiro, considerando, também, as recomendações da ANAC, até duas bagagens (uma de mão e uma de despacho), não são taxadas. Dessa forma, foram contabilizadas uma bagagem de mão e uma de despacho por passageiro.

Tendo definidas as quantidades de bagagens, para parametrizar a eficiência ótima dos processos aeroportuários, foi utilizado o *benchmark* gerado pela [IATA \(2022\)](#). O foco dessa pesquisa é o processo de check-in, desse modo a Figura 33 indica os tempos ótimos dessa etapa segundo a IATA. Cabe destacar que, o benchmark não se restringe apenas a aeroportos com *self bag drop*, logo, os dados são gerais. Com isso, tem-se que o tempo adequado para check-in, que inclui a etiquetagem e medida de bagagens, é de no máximo 7 minutos. Nos cálculos foram considerados apenas o tempo de medida da bagagem, que pode levar até 5 minutos.

Outra informação considerada, é o tempo médio máximo de check-in, esse dado varia entre as companhias e voos. Algumas recomendações orientam que é apropriado realizar check-in com 30 a 60 minutos de antecedência ao tempo de embarque, que, para uma aeronave como o A320, pode chegar a 30 minutos. Nesse contexto, o processo todo duraria até 90 minutos ([MINNESOTA, 2022; ANAC, 2016](#)). Na prática, é possível fazer check-in online, nos kiosks e nas filas de atendimento, contudo, para esse cenário, é considerado que todos os passageiros realizaram check-in nas filas utilizando as esteiras, todos dentro do prazo máximo de 60 minutos.

Baseado nessa informação, foi realizado o dimensionamento da quantidade de esteiras em paralelo necessárias para cumprir o tempo limite. A Tabela 9 mostra os resultados, é importante reiterar que foi considerado apenas o tempo de medida de bagagens. Os dados indicam que 1 esteira foi suficiente para cumprir o prazo de 60 minutos considerando a operação com o tempo ótimo para *self bag drop*. Para o modelo dessa pesquisa, 1 esteira também foi suficiente, mas comparado ao tempo ótimo, seriam



Figura 33 – Benchmark processo de check-in. Adaptado de ([IATA, 2022](#))

necessárias 2 esteiras para ter desempenho semelhante. Já o tempo máximo para *self bag drop* necessitou de 2 esteiras para não ultrapassar o limite. As demais métricas não alcançaram o objetivo, para a projeção média da IATA seriam necessárias 7 esteiras e para as recomendações máximas de *self bag drop* seriam necessárias 4.

Tipo de abordagem	Quantidade de passageiros	Tempo gasto de medida por passageiro (s)	Tempo gasto total com check-in utilizando 1 esteira(h)	Tempo gasto total com check-in utilizando 2 esteiras(h)	Tempo gasto total com check-in utilizando 3 esteiras (h)
Projeção da IATA (máximo)	150	300	12,5	6,3	4,17
Projeção da IATA (médio)	150	150	6,3	3,15	2,1
Recomendações <i>self-bag-drop</i> (máximo)	150	30	1,25	0,63	0,42
Recomendações <i>self-bag-drop</i> (ótimo)	150	15	0,63	0,32	0,21
Produto dessa pesquisa	150	19	0,80	0,4	0,27

Tabela 9 – Dimensionamento da operação do modelo proposto em comparação com diferentes métricas de mercado para aeronave A320

Os dados demonstram que, a solução proposta se aproxima dos resultados ótimos, sugerindo a necessidade de melhorias. Comparando os preços dos dispositivos de *self bag drop* do mercado com os sensores de profundidade, utilizado no produto dessa pesquisa, se tem maior economia direta utilizando 2 esteiras com os sensores de profundidade do que comprando 1 esteira com o dispositivo do mercado. Cabe recapitular que esse é um cenário simulado, que desconsidera dados dinâmicos e aleatórios, contudo, ele indica que o produto dessa pesquisa tem potencial de ser aplicado na prática.

5 Conclusão

A presente pesquisa investigou a viabilidade técnica de se utilizar dispositivos de baixo custo na obtenção das dimensões de bagagens aeroportuárias. Para tanto, foi realizada uma revisão sistemática onde foram selecionados 14 trabalhos de um total de 167. Tais trabalhos, aprovados nos critérios determinados por este estudo, empregaram técnicas de PDI e reconstrução de objetos 3D, sendo que todos utilizaram *point clouds*. Para extração da *point cloud*, foram usados métodos tais como visão binocular, scanners a laser e sensores de profundidade.

Dos trabalhos que propuseram tecnologias alternativas, foi dado destaque ao Kinect. Esta ferramenta tem baixo custo e alta precisão, de modo que é possível reconstruir objetos com fidelidade. Portanto, sensores baseados em IR (infravermelho) e câmeras, são alternativas para a criação de sistemas baixo custo. No entanto, nos trabalhos identificados, o kinect foi utilizado em outros escopos que não os terminais de medidas de bagagens. Ainda, as soluções desenvolvidas nos trabalhos apresentam limitações, como a alta influência do formato e posição do objeto nos resultados.

Posteriormente, para explorar a viabilidade técnica do uso dos sensores de profundida no problema abordado, foi construído um protótipo. Para tanto, foi utilizado o sensor kinect v2 para captura da *point cloud* da bagagem, fixando-o em uma estrutura de esteira automatizada. O protótipo consegue retornar as dimensões de bagagens de mão ou de despacho.

Para avaliar o modelo proposto, foram realizados testes considerando diferentes posições do sensor e das bagagens (em pé, de lado e deitada). Os resultados expostos na Sessão 4 mostram que o sistema conseguiu obter a *point cloud* e calcular as dimensões das bagagens com um MAE total de 2,86 cm. O tempo médio gasto por medida é de 0,14 s/cm. Isso indica que o sistema precisa de melhorias no tempo consumido. Esses dados demonstram haver potencial para o uso dessa alternativa de baixo custo na gestão de operações de embarque em companhias aéreas. Ao reduzir os erros de medição, é possível otimizar o uso do espaço na aeronave, reduzir prejuízos a companhia e aliviar as frustrações dos passageiros.

Uma limitação deste estudo é a simulação da aplicação do dispositivo no processo de check-in, abordada de maneira simplificada na Seção 4.3. Como trabalho futuro, serão realizadas simulações mais avançadas utilizando o software Arena. Essas simulações permitirão considerar diversos elementos do cenário, como múltiplas filas, *self bag drop*, ocorrências aleatórias e diferentes setores do aeroporto. Os resultados iniciais de simulações com o programa, sugerem que o dispositivo proposto se aproxima dos resultados do

mercado. Contudo, é necessária uma análise aprofundada considerando todo o processo, incluindo o tempo de espera nas filas, procedimentos do check-in, medidas de segurança e embarque na aeronave.

Além disso, compondo os trabalhos futuros desta pesquisa, tem-se o aprofundamento dos testes referentes à quantidade de bagagem por medida, bem como explorar o impacto de alças, rodas e etiquetas nos resultados. Almeja-se explorar, também, a obtenção do peso da bagagem e avaliar situações de malas fora do padrão ou com deformações. Essas análises adicionais contribuirão para uma compreensão mais abrangente do desempenho do dispositivo em cenários práticos.

Referências

ACTORSFIT. PCL PCA minimum bounding box (draw the vertex of the minimum bounding box). 2021. Disponível em: <<https://blog.actorsfit.com/a?ID=01750-b3f152c7-c1a1-4ea5-a64f-a53bf8677bc7>>. Citado na página 30.

AIRFRANCE. Air France chooses new, more spacious luggage compartments by Safran to equip its Airbus A320 fleet | Air France - Corporate. 2019. Disponível em: <<https://www.safran-group.com/pressroom/air-france-chooses-new-more-spacious-luggage-compartments-safran-equip-its-airbus-a320-fleet-2019-10-02>>. Citado na página 59.

AIRLINES, U. Check-in and Airport Processing Times. 2020. Disponível em: <<https://www.united.com/ual/en/us/fly/travel/airport/process.html>>. Citado na página 13.

ALSYOUF, I. et al. Improving baggage flow in the baggage handling system at a uae-based airline using lean six sigma tools. **Quality Engineering**, v. 30, p. 432–452, 03 2018. Disponível em: <<https://doi.org/10.1080/08982112.2018.1437180>>. Citado na página 13.

ANAC. ANAC orienta passageiros sobre horário de check-in e embarque. 2016. Disponível em: <<https://www.gov.br/anac/pt-br/noticias/2016/anac-orienta-passageiros-sobre-horario-de-check-in-e-embarque#:~:text=Geralmente%2C%20as%20companhias%20a%C3%A9reas%20abrem>>. Citado na página 60.

ANAC. RESOLUÇÃO Nº 400, 13/12/2016 — Agência Nacional de Aviação Civil ANAC. 2022. Disponível em: <<https://www.anac.gov.br/assuntos/legislacao/legislacao-1/resolucoes/resolucoes-2016/resolucao-no-400-13-12-2016>>. Citado na página 19.

ANDERSON, K. Singapore Changi Airport caught using Microsoft Kinect sensors - OnMSFT.com. 2019. Disponível em: <<https://www.onmsft.com/news/singapore-changi-airport-caught-using-microsoft-kinect-sensors>>. Citado na página 13.

APPELT, S. et al. Simulation of passenger check-in at a medium-sized us airport. 2007. 1252–1260 p. Disponível em: <<https://ieeexplore.ieee.org/abstract/document/4419729/>>. Citado na página 59.

AZUL. Bagagem Despachada. 2022. Disponível em: <<https://www.voeazul.com.br/para-sua-viagem/informacoes-para-viar/bagagem-despachada>>. Citado na página 19.

BHOWMIK, D.; APPIAH, K. Embedded vision systems: A review of the literature. **Applied Reconfigurable Computing. Architectures, Tools, and Applications**, p. 204–216, 2018. Disponível em: <http://dx.doi.org/10.1007/978-3-319-78890-6_17>. Citado na página 20.

BOURQUE, P.; FAIRLEY, R. Guide to the Software Engineering Body of Knowledge SWEBOK ® A Project of the IEEE Computer Society. 2015. Disponível em: <<https://cs.fit.edu/~kgallagher/Schtick/Serious/SWEBOKv3.pdf>>. Citado na página 40.

- CARGO, A. **A320/321ANA Cargo**. 2023. Disponível em: <<https://www.anacargo.jp/en/int/specification/a320.html>>. Citado 4 vezes nas páginas 8, 9, 59 e 60.
- CHAN, T. et al. An egg volume measurement system based on the microsoft kinect. **Sensors**, v. 18, p. 2454, 07 2018. Disponível em: <<https://doi.org/10.3390/s18082454>>. Citado 5 vezes nas páginas 14, 24, 25, 33 e 35.
- CHEN, J. M. et al. Research on landscape environment with 3d-reconstruction and volume measurement of fruit tree canopy based on kinect. **Advanced Materials Research**, v. 788, p. 480–485, 09 2013. Disponível em: <<https://doi.org/10.4028/www.scientific.net/AMR.788.480>>. Citado 7 vezes nas páginas 14, 15, 20, 24, 28, 33 e 53.
- CNPQ. **Engenharias - Plataforma Lattes - CNPq**. 2022. Disponível em: <<http://lattes.cnpq.br/web/dgp/engenharias>>. Citado na página 39.
- COLBY, M. **Self-service bag drops and the challenges of speeding up airport baggage check-in**. 2019. Disponível em: <<https://www.stantec.com/en/ideas/self-service-bag-drops-and-the-challenges-of-speeding-up-airport-baggage-check-in>>. Citado na página 13.
- DANIEL. **Como fazer check-in online, no celular ou no aeroporto para o seu voo?** 2021. Disponível em: <<https://www.melhoresdestinos.com.br/como-fazer-check-in.html>>. Citado na página 19.
- DAVID. **Computing oriented minimum bounding boxes in 2D**. 2014. Disponível em: <<https://geidav.wordpress.com/2014/01/23/computing-oriented-minimum-bounding-boxes-in-2d/>>. Citado 3 vezes nas páginas 7, 30 e 31.
- DENIS. **Bagagem no avião: guia completo e dicas de como despachar suas malas grátis!** 2021. Disponível em: <<https://www.melhoresdestinos.com.br/bagagem-viagem-aviao.html#:~:text=Em%20voos%20dom%C3%A9sticos%2C%20a%20bagagem>>. Citado na página 19.
- DING, S. et al. A fast algorithm of convex hull vertices selection for online classification. **IEEE Transactions on Neural Networks and Learning Systems**, v. 29, p. 792–806, 04 2018. Disponível em: <<https://doi.org/10.1109/TNNLS.2017.2648038>>. Citado na página 29.
- FTE. **The efficiencies of common bag drop**. 2008. Disponível em: <<https://www.futuretravelexperience.com/2008/09/the-efficiencies-of-common-bag-drop/>>. Citado na página 59.
- GAO, Q.; LIANG, P. Airline baggage appearance transportability detection based on a novel dataset and sequential hierarchical sampling cnn model. **IEEE Access**, v. 9, p. 41833–41843, 2021. Disponível em: <<https://doi.org/10.1109/ACCESS.2021.3065705>>. Citado 3 vezes nas páginas 13, 14 e 22.
- GAO, Q. et al. Minimum elastic bounding box algorithm for dimension detection of 3d objects: a case of airline baggage measurement. **IET Image Processing**, v. 12, p. 1313–1321, 08 2018. Disponível em: <<https://doi.org/10.1049/iet-ipr.2017.0695>>. Citado 10 vezes nas páginas 7, 13, 14, 15, 22, 23, 29, 33, 34 e 53.

- GAO, Q. J.; YANG, L. Baggage specification detection based on the binocular vision. **Applied Mechanics and Materials**, v. 278-280, p. 861–865, 01 2013. Disponível em: <<https://doi.org/10.4028/www.scientific.net/AMM.278-280.861>>. Citado 4 vezes nas páginas 24, 33, 34 e 41.
- GOCMEN, E. Smart airport: Evaluation of performance standards and technologies for a smart logistics zone. **Transportation Research Record: Journal of the Transportation Research Board**, v. 2675, p. 480–490, 07 2021. Disponível em: <<https://doi.org/10.1177%2F03611981211019740>>. Citado na página 13.
- GOL. Bagagem | GOL Linhas Aéreas. 2022. Disponível em: <<https://www.voegol.com.br/informacoes/bagagem>>. Citado na página 19.
- GOMES, J. F. S.; LETA, F. R. Applications of computer vision techniques in the agriculture and food industry: a review. **European Food Research and Technology**, v. 235, p. 989–1000, 10 2012. Citado na página 15.
- GUFFANTI, D. et al. The accuracy of the microsoft kinect v2 sensor for human gait analysis. a different approach for comparison with the ground truth. **Sensors**, v. 20, p. 4405, 08 2020. Disponível em: <<https://doi.org/10.3390/s20164405>>. Citado 2 vezes nas páginas 25 e 53.
- HARMAN, M. **DBSCAN with Python**. 2020. Disponível em: <<https://towardsdatascience.com/dbSCAN-with-python-743162371dca>>. Citado 3 vezes nas páginas 7, 32 e 33.
- HU, Q. et al. Accuracy improvement of binocular vision measurement system for slope deformation monitoring. **Sensors**, v. 20, p. 1994, 04 2020. Disponível em: <<https://doi.org/10.3390/s20071994>>. Citado 2 vezes nas páginas 7 e 24.
- HUMPHRIES, M. **Newark Airport Is Using Xbox Kinect Sensors for Surveillance**. 2019. Disponível em: <<https://www.pcmag.com/news/newark-airport-is-using-xbox-kinect-sensors-for-surveillance>>. Citado na página 13.
- HYYPPÄ, E. et al. Accurate derivation of stem curve and volume using backpack mobile laser scanning. **ISPRS Journal of Photogrammetry and Remote Sensing**, v. 161, p. 246–262, 03 2020. Disponível em: <<https://doi.org/10.1016/j.isprsjprs.2020.01.018>>. Citado na página 22.
- HYYPPÄ, E. et al. Comparison of backpack, handheld, under-canopy uav, and above-canopy uav laser scanning for field reference data collection in boreal forests. **Remote Sensing**, v. 12, p. 3327, 10 2020. Disponível em: <<https://doi.org/10.3390/rs12203327>>. Citado na página 33.
- IATA. **Level of Service Concept**. 2022. Disponível em: <<https://www.iata.org/en/services/consulting/airport-pax-security/level-of-service/#tab-1>>. Citado 4 vezes nas páginas 8, 59, 60 e 61.
- ICAO. **The World of Air Transport in 2019**. 2019. Disponível em: <<https://www.icao.int/annual-report-2019/Pages/the-world-of-air-transport-in-2019.aspx>>. Citado na página 13.

- INMETRO. **Documentos Técnicos em Metrologia.** 2022. Disponível em: <https://www.gov.br/inmetro/pt-br/centrais-de-conteudo/publicacoes/documentos-tecnicos-em-metrologia/vim_2012.pdf>. Citado na página 21.
- INTEL. **Introducing the Intel® RealSense™ Depth Camera D455.** 2021. Disponível em: <<https://www.intelrealsense.com/depth-camera-d455/>>. Citado na página 25.
- JIAO, J. et al. A post-rectification approach of depth images of kinect v2 for 3d reconstruction of indoor scenes. **ISPRS International Journal of Geo-Information**, v. 6, p. 349, 11 2017. Disponível em: <<https://doi.org/10.3390/ijgi6110349>>. Citado na página 26.
- KUCUK, H. et al. Development of a dimensions measurement system based on depth camera for logistic applications. **Eleventh International Conference on Machine Vision (ICMV 2018)**, 03 2019. Disponível em: <<https://doi.org/10.11117/12.2523123>>. Citado na página 13.
- LAURINI, R. **Geographic Knowledge Infrastructure: Applications to Territorial Intelligence and Smart Cities.** Elsevier, 2017. Disponível em: <<https://books.google.com.br/books?hl=pt-BR&lr=&id=bQUsDgAAQBAJ&oi=fnd&pg=PP1&dq=LAURINI>>. Citado na página 30.
- LI, S.; YANG, X. The research of binocular vision ranging system based on labview. **AIP Conference Proceedings**, 2017. Disponível em: <<https://doi.org/10.1063/1.5005258>>. Citado na página 24.
- LIMWATTANAPIBOOL, O.; ARCH-INT, S. Determination of the appropriate parameters for k-means clustering using selection of region clusters based on density dbscan (srcd-dbscan). **Expert Systems**, v. 34, p. e12204, 05 2017. Disponível em: <<https://doi.org/10.1111/exsy.12204>>. Citado na página 29.
- MATHWORK. **Image Acquisition Toolbox Support Package for Kinect For Windows Sensor.** 2022. Disponível em: <<https://www.mathworks.com/matlabcentral/fileexchange/40445-image-acquisition-toolbox-support-package-for-kinect-for-windows-sensor>>. Citado na página 41.
- MATHWORKS. **Point cloud from Kinect for Windows - MATLAB pcfromkinect.** 2015. Disponível em: <<https://www.mathworks.com/help/vision/ref/pcfromkinect.html>>. Citado na página 41.
- MATHWORKS. **Acquire Image and Body Data Using Kinect V2 - MATLAB Simulink.** 2017. Mathworks, 2017. 2017. Disponível em: <<https://www.mathworks.com/help/supportpkg/kinectforwindowsruntime/ug/acquire-image-and-body-data-using-kinect-v2.html>>. Citado 2 vezes nas páginas 26 e 41.
- MATHWORKS. **MATLAB - MathWorks.** 2019. Disponível em: <<https://www.mathworks.com/products/matlab.html>>. Citado na página 40.
- MATHWORKS. **Image Acquisition Toolbox.** 2022. www.mathworks.com, 2022. 2022. Disponível em: <<https://www.mathworks.com/products/image-acquisition.html>>. Citado na página 41.

- MATHWORKS. **Introduction to Lidar - MATLAB Simulink.** 2022. Disponível em: <<https://www.mathworks.com/help/lidar/ug/lidar-processing-overview.html>>. Citado 2 vezes nas páginas 7 e 23.
- MINNESOTA, U. of. **Airport Check-In | Learning Abroad Center.** 2022. Disponível em: <<https://umabroad.umn.edu/resources/travel/airport>>. Citado na página 60.
- MOHER, D. Preferred reporting items for systematic reviews and meta-analyses: the prisma statement (chinese edition). **Journal of Chinese Integrative Medicine**, v. 7, p. 889–896, 09 2009. Disponível em: <<https://doi.org/10.3736/jcim20090918>>. Citado na página 17.
- MOUSAVIAN, A. et al. **3D Bounding Box Estimation Using Deep Learning and Geometry.** 2017. 7074–7082 p. Disponível em: <https://openaccess.thecvf.com/content_cvpr_2017/html/Mousavian_3D_Bounding_Box_CVPR_2017_paper.html>. Citado na página 31.
- NEALE, O. **Automated Bag Drop: How do one-step and two-step bag drop systems impact on airports - Part one.** 2017. Disponível em: <<https://www.aiqconsulting.com/blog/automated-bag-drop-how-do-one-step-and-two-step-bag-drop-systems-impact-on-airports-part-one/>>. Citado na página 22.
- NEETHU, N.; ANOOP, B. Role of computer vision in automatic inspection system. **International Journal of Computer Applications**, v. 123, 2015. Disponível em: <https://www.researchgate.net/profile/Anoop-Kadan-2/publication/281719495_Role_of_Computer_Vision_in_Automatic_Inspection_Systems/links/5a0c703b4585153829b170c2/Role-of-Computer-Vision-in-Automatic-Inspection-Systems.pdf>. Citado 3 vezes nas páginas 14, 20 e 29.
- NEGRI, N.; BORILLE, G. Avaliação da influência de novas tecnologias em terminais de passageiros aeroportuários sob a Ótica dos passageiros. **ANPET**, 01 2017. Disponível em: <<https://abre.ai/eG4j>>. Citado na página 13.
- OZBAY, E.; CINAR, A. 3d reconstruction technique with kinect and point cloud computing. **Global Journal on Technology**, v. 3, 06 2013. Disponível em: <<http://archives.un-pub.eu/index.php/P-ITCS/article/viewArticle/2009>>. Citado 3 vezes nas páginas 33, 34 e 37.
- PROTEUS. **PCB Design and Circuit Simulator Software - Proteus.** 2022. Disponível em: <<https://www.labcenter.com/>>. Citado na página 45.
- QINGJI, G.; CHUANBO, P.; QIJUN, L. Method on 3d reconstruction of airline baggage based on active laser projection of improved encoding. **2018 IEEE CSAA Guidance, Navigation and Control Conference (CGNCC)**, v. 39, 08 2018. Disponível em: <<https://doi.org/10.1109/GNCC42960.2018.9018713>>. Citado 6 vezes nas páginas 13, 22, 24, 33, 34 e 41.
- REN, X.; ZHOU, X.; XU, X. A new model of luggage storage time while boarding an airplane: An experimental test. **Journal of Air Transport Management**, v. 84, p. 101761, 05 2020. Disponível em: <<https://doi.org/10.1016/j.jairtraman.2019.101761>>. Citado 2 vezes nas páginas 13 e 22.

- RONZANI, G. M.; CORREIA, A. R. Impact of demand and airport characteristics on baggage claim. **Proceedings of the Institution of Civil Engineers - Transport**, v. 168, p. 150–160, 04 2015. Disponível em: <<https://doi.org/10.1680/tran.12.00048>>. Citado na página 13.
- RONZANI, G. M. et al. **Exploração de formas de coleta de dados para monitoramento operacional em terminais aeroportuários (Relatório III): Metodologia de medição de desempenho (tempo de espera na fila) dos pontos de processamento de passageiros e bagagens no aeroporto, com definição de indicadores e metas de desempenho**. [S.l.]: MediDes (Publicação Restrita: SAC), 2019. 53 p. Citado 3 vezes nas páginas 9, 26 e 27.
- RUCHAY, A.; DOROFEEV, K.; KOLPAKOV, V. Fusion of information from multiple kinect sensors for 3d object reconstruction. **Computer Optics**, v. 42, p. 898–903, 2018. Disponível em: <<https://doi.org/10.18287/2412-6179-2018-42-5-898-903>>. Citado 6 vezes nas páginas 24, 25, 29, 33, 35 e 37.
- RYU, M. W. et al. Algorithm for generating 3d geometric representation based on indoor point cloud data. **Applied Sciences**, v. 10, p. 8073, 11 2020. Disponível em: <<https://doi.org/10.3390/app10228073>>. Citado 2 vezes nas páginas 33 e 35.
- SCHUBERT, E. et al. Dbscan revisited, revisited: Why and how you should (still) use dbscan. **ACM Transactions on Database Systems**, v. 42, p. 1–21, 08 2017. Disponível em: <<https://doi.org/10.1145/3068335>>. Citado na página 32.
- SHIN, D.-W.; HO, Y.-S. Implementation of 3d object reconstruction using a pair of kinect cameras. **Signal and Information Processing Association Annual Summit and Conference (APSIPA), 2014 Asia-Pacific**, 12 2014. Disponível em: <<https://doi.org/10.1109/APSIPA.2014.7041651>>. Citado 3 vezes nas páginas 29, 33 e 35.
- SIWEI, H.; BAOLONG, L. Review of bounding box algorithm based on 3d point cloud. **International Journal of Advanced Network, Monitoring and Controls**, v. 6, p. 18–23, 01 2021. Disponível em: <<https://doi.org/10.21307/ijanmc-2021-003>>. Citado 2 vezes nas páginas 30 e 31.
- STATISTA. **Airline industry - passenger traffic worldwide 2019 | Statistic**. Statista, 2020. Disponível em: <<https://www.statista.com/statistics/564717/airline-industry-passenger-traffic-globally/>>. Citado na página 13.
- SUN, G.; WANG, X. Three-dimensional point cloud reconstruction and morphology measurement method for greenhouse plants based on the kinect sensor self-calibration. **Agronomy**, v. 9, p. 596, 09 2019. Disponível em: <<https://doi.org/10.3390/agronomy9100596>>. Citado 3 vezes nas páginas 24, 33 e 35.
- TURRIONI, J.; MELLO, C. **Metodologia de Pesquisa em Engenharia de Produção**. 1. ed. [S.l.]: UNIFEI, 2012. Citado na página 39.
- WAN, Y. et al. A study in 3d-reconstruction using kinect sensor. **2012 8th International Conference on Wireless Communications, Networking and Mobile Computing**, 09 2012. Disponível em: <<https://doi.org/10.1109/WiCOM.2012.6478374>>. Citado 5 vezes nas páginas 14, 24, 29, 33 e 35.

- WARNETT, J. M. et al. Towards in-process x-ray ct for dimensional metrology. **Measurement Science and Technology**, v. 27, p. 035401, 01 2016. Disponível em: <<http://dx.doi.org/10.1088/0957-0233/27/3/035401>>. Citado 3 vezes nas páginas 20, 33 e 35.
- XU, D. et al. Lidar applications to estimate forest biomass at individual tree scale: Opportunities, challenges and future perspectives. **Forests**, v. 12, p. 550, 04 2021. Disponível em: <<https://doi.org/10.3390/f12050550>>. Citado na página 23.
- ZHANG, Y. et al. A kinect-based approach for 3d pavement surface reconstruction and cracking recognition. **IEEE Transactions on Intelligent Transportation Systems**, v. 19, p. 3935–3946, 12 2018. Disponível em: <<https://doi.org/10.1109/TITS.2018.2791476>>. Citado 2 vezes nas páginas 13 e 23.
- ZHAO, J. et al. 3d fast convex-hull-based evolutionary multiobjective optimization algorithm. **Applied Soft Computing**, v. 67, p. 322–336, 06 2018. Disponível em: <<https://doi.org/10.1016/j.asoc.2018.03.005>>. Citado 2 vezes nas páginas 29 e 30.
- ZHENG, P. et al. Smart manufacturing systems for industry 4.0: Conceptual framework, scenarios, and future perspectives. **Frontiers of Mechanical Engineering**, v. 13, p. 137–150, 01 2018. Disponível em: <<https://doi.org/10.1007/s11465-018-0499-5>>. Citado 2 vezes nas páginas 14 e 20.
- ZHOU, S. et al. Extracting diameter at breast height with a handheld mobile lidar system in an outdoor environment. **Sensors**, v. 19, p. 3212, 07 2019. Disponível em: <<https://doi.org/10.3390/s19143212>>. Citado 2 vezes nas páginas 23 e 33.
- ZRHANS. **Acurácia, Precisão e Exatidão**. 2018. Disponível em: <<https://portalfisica.com/2018/08/24/acuracia-precisao-e-exatidao/>>. Citado na página 21.

Apêndices

APÊNDICE A – Códigos-fonte do sistema de medida de bagagens

Este apêndice fornece os links para os repositórios dos códigos-fonte desenvolvidos durante a pesquisa para criar o protótipo da solução. Como detalhado ao longo do texto, o produto final consiste em duas partes, o software em Matlab e o código em Arduino, sendo eles:

- **Código em Matlab:** responsável pela interface de usuário, integração com o sensor Kinect e com a esteira de bagagens. Após a coleta da point cloud é executada a função de medida que computa as dimensões e retorna os dados para o usuário. O link para o repositório é o seguinte <https://github.com/Vitor0534/Get_obj_dimensions_Kinect>;
- **Código em Arduino:** responsável pela automação do hardware do sistema. Realiza o controle da esteira e contém um módulo de configuração via porta serial. A interface via porta serial reconhece diversos comandos padronizados para alteração de velocidade, direção e precisão do controlador RPM, também é possível fazer o mesmo por um painel físico. O link para o repositório é o seguinte <<https://github.com/Vitor0534/CodigoPrototipoEsteira>>;

APÊNDICE B – Interface de usuário

O presente apêndice ilustra a interface de usuário desenvolvida para o protótipo, tal interface pode ser observada na Figura 34. Esse recurso foi implementado para facilitar a operação do sistema e realização de testes com diferentes parâmetros.

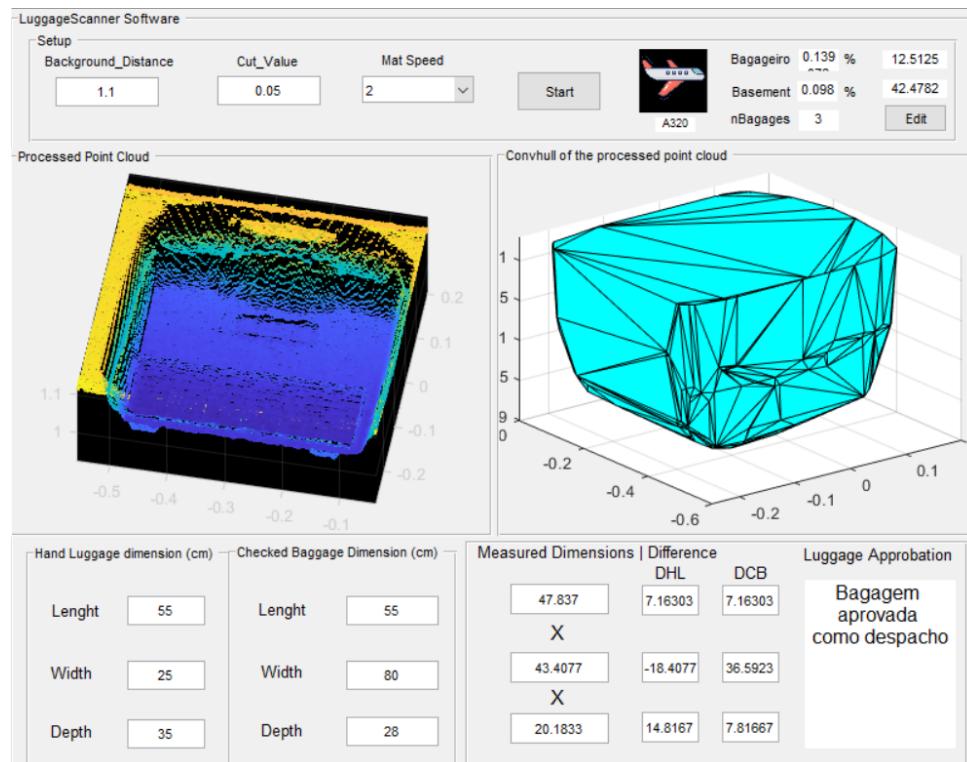


Figura 34 – Interface de usuário do protótipo desenvolvido na presente pesquisa

Dentre as ações disponibilizadas existe a opção de indicar as dimensões máximas de bagagens de mão e despacho (comprimento, altura e profundidade) e, também, iniciar o processamento. As demais opções podem ser pontuadas na seguinte ordem:

- Setup: permite a configuração de parâmetros do sensor, tal como distância a base, valor de corte e velocidade da esteira. Também contém elementos para visualização do volume em m^3 consumido no bagageiro/porão da aeronave e o número de bagagens aprovadas;
- Visualização de *point cloud*: a *point cloud* e o polígono mínimo são plotados nos dois gráficos centrais;
- Campo de dimensões medidas: componente de saída que irá listar os resultados da medida da bagagem. Os dados são disponibilizados em termos de comprimento,

altura e profundidade. O campo "DHL" disponibiliza a diferença entre o valor máximo permitido para bagagem de mão e o obtido na medida, o "DCB" faz o mesmo para bagagem de despacho. O campo de aprovação de bagagem apenas mostra uma mensagem de bagagem aprovada ou não.